

机器学习笔记

魏舟

2026 年 1 月 23 日

这是我自己写的一个机器学习笔记。初写于 2026 年 1 月 19 日，于南京理工大学 25 舍 313 宿舍，正值我前往新加坡访学前夕。

目录

1 数学基础	4
1.1 数学分析	4
1.1.1 上/下确界 (Supremum & Infimum)	4
1.1.2 李普希茨连续性 (Lipschitz Continuity)	4
1.1.3 雅可比矩阵 (Jacobian Matrix)	5
1.1.4 Hessian 矩阵	6
1.1.5 多元函数的凹凸性 (Convexity)	6
1.1.6 多元函数的泰勒公式	6
1.1.7 多重积分换元法与 Normalizing Flows	7
1.2 高等代数	7
1.2.1 向量的范数 (Vector Norms)	7
1.2.2 矩阵的范数与谱范数 (Matrix Norms)	7
1.2.3 Householder 变换与 QR 算法	8
1.2.4 广义特征值与瑞利商 (Rayleigh Quotient)	8
1.2.5 矩阵的条件数 (Condition Number)	8
1.2.6 矩阵分解 (Matrix Decompositions)	9
1.3 概率论	9
1.3.1 条件独立性 (Conditional Independence)	9
1.3.2 Jensen 不等式 (Jensen's Inequality)	9
1.3.3 典型概率分布	9
1.3.4 多维正态分布 (Multivariate Normal Distribution)	9
1.3.5 概率分布变换 (Change of Variables)	10
1.3.6 参数估计: MLE, MAP 与贝叶斯估计	10
1.3.7 随机数生成算法 (Sampling Methods)	10
1.4 最优化方法 (机器学习算法的动力源泉)	10
1.4.1 基本概念与分类	10
1.4.2 一阶优化方法: 梯度下降及其变体	10
1.4.3 二阶优化方法: 利用曲率信息	11
1.4.4 带约束的优化: 拉格朗日对偶性	11
1.4.5 针对特殊结构的优化算法	11
1.4.6 深度学习中的自适应优化器	12
1.4.7 二阶近似: 拟牛顿法 (L-BFGS)	12
1.5 信息论 (Information Theory)	13
1.5.1 熵与自信息 (Entropy & Self-information)	13
1.5.2 联合熵与条件熵 (Joint & Conditional Entropy)	13
1.5.3 互信息 (Mutual Information)	13
1.5.4 相对熵 (KL 散度)	13
1.5.5 交叉熵 (Cross-Entropy)	13
1.5.6 最大熵原理 (Principle of Maximum Entropy)	14
1.6 随机过程 (Stochastic Processes)	14
1.6.1 基本概念	14

1.6.2	平稳过程 (Stationary Processes)	14
1.6.3	马尔可夫过程 (Markov Processes)	14
1.6.4	高斯过程 (Gaussian Processes, GP)	14
1.6.5	维纳过程与布朗运动 (Wiener Process)	14
1.6.6	泊松过程 (Poisson Process)	15
1.6.7	随机微分方程 (SDE) 简介	15
2	机器学习基础 (Machine Learning Basics)	15
3	线性回归模型 (Linear Regression Model)	15
3.1	评价指标与损失函数	16
3.2	求解方法	16
4	逻辑回归 (Logistic Regression)	16

1 数学基础

1.1 数学分析

1.1.1 上/下确界 (Supremum & Infimum)

在机器学习中，确界常用于定义泛化误差的上界。对于集合 $S \subseteq \mathbb{R}$ ，若存在 M 使得 $\forall x \in S, x \leq M$ ，则称 M 为上界。其最小上界称为上确界，记作 $\sup S$ 。

- 在优化中的应用：最小化目标函数 $f(x)$ 等价于寻找其下确界 $\inf_{x \in \mathcal{X}} f(x)$ 。

1.1.2 李普希茨连续性 (Lipschitz Continuity)

定义：若存在常数 $L \geq 0$ （李普希茨常数），使得对于函数定义域内的任意 x_1, x_2 ，都有：

$$|f(x_1) - f(x_2)| \leq L \|x_1 - x_2\|$$

则称 f 是 L -Lipschitz 连续的。

- 机器学习意义：

1. 稳定性：限制了输入扰动对模型输出的影响。

稳定性 (Stability) 的深层解释 稳定性是连接数学理论与模型泛化能力的桥梁，主要体现在以下三个方面：

1. **鲁棒性 (Robustness)**：由 $|f(x + \delta) - f(x)| \leq L \|\delta\|$ 可知， L 限制了扰动在网络中的放大倍数。在安全敏感的应用中，通过限制 L 可以有效防御对抗样本攻击，确保模型不会因微小的输入变化而产生剧烈的输出波动。
2. **泛化保证 (Generalization)**：统计学习理论证明，若算法满足 *Uniform Stability*，其泛化误差的上界与 L 相关。低 Lipschitz 常数意味着模型函数更加平滑，不会过度拟合训练集中的离群点。
3. **训练稳定性**：在深度网络中，若各层算子的谱范数（即其 L ）远离 1，会导致梯度爆炸或消失。通过规范化技术（如 Spectral Norm）将每层约束为 1-Lipschitz，可以使深层网络的梯度传播更加稳定，进而允许使用更大的学习率。

优化中的收敛性保证 若目标函数 $\mathcal{L}$ 的梯度是 L -Lipschitz 的（即 L -smooth），则有：

$$\mathcal{L}(\mathbf{w}_{k+1}) \leq \mathcal{L}(\mathbf{w}_k) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla \mathcal{L}(\mathbf{w}_k)\|^2$$

当学习率 $\eta < \frac{2}{L}$ 时，优化过程能保证单调下降，这提供了算法层面的稳定性。

2. **优化**：若梯度的范数被 L 限制，则梯度下降的步长（学习率）可以被安全地设为 $1/L$ 而不至于震荡。

优化中的收敛性推导 若目标函数 f 满足 L -smooth 条件，由下降引理可得：

$$f(\mathbf{x} - \eta \nabla f(\mathbf{x})) \leq f(\mathbf{x}) - \eta \left(1 - \frac{L\eta}{2}\right) \|\nabla f(\mathbf{x})\|^2 \quad (1)$$

由此可见：

- 若 $\eta < 2/L$ ，函数值保证下降。
- 若 $\eta = 1/L$ ，单步下降的理论界达到最优。
- 若 $\eta > 2/L$ ，步长过大可能导致跨过极小值点，产生震荡甚至发散。

3. WGAN: 在 Wasserstein GAN 中，判别器被要求满足 1-Lipschitz 连续，以保证 Wasserstein 距离的对偶性成立。

WGAN 中的 Lipschitz 约束 WGAN 旨在最小化 Wasserstein 距离。通过对偶原理，目标函数转化为：

$$\min_G \max_{D \in \mathcal{F}} E_{x \sim P_r}[D(x)] - E_{z \sim P(z)}[D(G(z))] \quad (2)$$

其中 $\mathcal{F}$ 是所有满足 1-Lipschitz 连续的函数集合。

- **对偶意义：** 约束 Lipschitz 性质保证了 Wasserstein 距离的定义有效，并使判别器（评论员）的梯度变得平滑。
- **梯度惩罚：** $L_{GP} = E_{\hat{x}}[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2]$ ，这使得 D 在数据样本附近的斜率保持在 1 左右。

1.1.3 雅可比矩阵 (Jacobian Matrix)

设 $\mathbf{f}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是一个向量值函数，其雅可比矩阵 $\mathbf{J} \in \mathbb{R}^{m \times n}$ 定义为：

$$\mathbf{J} = \frac{\partial(f_1, \dots, f_m)}{\partial(x_1, \dots, x_n)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \cdots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

雅可比矩阵的运算与性质

1. **链式法则 (Chain Rule):** 若 $\mathbf{z} = \mathbf{g}(\mathbf{y})$ 且 $\mathbf{y} = \mathbf{f}(\mathbf{x})$ ，则复合函数的雅可比矩阵为矩阵乘积：

$$\mathbf{J}_{\mathbf{g} \circ \mathbf{f}}(\mathbf{x}) = \mathbf{J}_{\mathbf{g}}(\mathbf{y}) \mathbf{J}_{\mathbf{f}}(\mathbf{x})$$

这是深度学习反向传播算法的理论支柱。

2. **线性映射性质：** 在点 $\mathbf{x}_0$ 附近，函数 $\mathbf{f}$ 可以近似为线性变换：

$$\mathbf{f}(\mathbf{x}) \approx \mathbf{f}(\mathbf{x}_0) + \mathbf{J}_{\mathbf{f}}(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0)$$

3. **体积变化率：** 在积分换元或概率密度变换中，雅可比行列式 $|\det(\mathbf{J})|$ 描述了局部单位体积经 $\mathbf{f}$ 变换后的体积变化比例。
4. **逆映射性质：** 若 $\mathbf{J}_{\mathbf{f}}$ 在某点处非奇异 ($\det(\mathbf{J}) \neq 0$)，则在该点附近存在局部逆映射，且其雅可比矩阵满足 $\mathbf{J}_{\mathbf{f}^{-1}} = \mathbf{J}_{\mathbf{f}}^{-1}$ 。

推导应用： 在神经网络的反向传播中，链式法则本质上是雅可比矩阵的连乘：

$$\frac{\partial \mathcal{L}}{\partial \mathbf{x}} = \frac{\partial \mathcal{L}}{\partial \mathbf{y}} \cdot \frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \nabla_{\mathbf{y}} \mathcal{L} \cdot \mathbf{J}_{\mathbf{y}(\mathbf{x})}$$

1.1.4 Hessian 矩阵

对于二阶可微实函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，其 Hessian 矩阵 $\mathbf{H}$ 刻画了函数的二阶偏导数（曲率）：

$$\mathbf{H}_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

- 牛顿法迭代公式： $\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{H}^{-1}(\mathbf{x}_k) \nabla f(\mathbf{x}_k)$ 。

牛顿迭代公式的推导 对 $f(\mathbf{x})$ 在 $\mathbf{x}_k$ 处进行二阶泰勒展开：

$$f(\mathbf{x}) \approx f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \mathbf{H}(\mathbf{x}_k) \Delta \mathbf{x}$$

其中 $\Delta \mathbf{x} = \mathbf{x} - \mathbf{x}_k$ 。令该二次近似函数对 $\Delta \mathbf{x}$ 的导数为 $\mathbf{0}$ ：

$$\frac{\partial}{\partial \Delta \mathbf{x}} \left(\nabla f(\mathbf{x}_k)^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \mathbf{H}_k \Delta \mathbf{x} \right) = \nabla f(\mathbf{x}_k) + \mathbf{H}_k \Delta \mathbf{x} = \mathbf{0}$$

由此得到迭代步长 $\Delta \mathbf{x} = -\mathbf{H}_k^{-1} \nabla f_k$ 。

- **特征值意义：** 若 $\mathbf{H}$ 正定，则该点为极小值点；特征值的大小代表了在该方向上的下降速度。

Hessian 特征值的几何与优化意义 设 $\mathbf{H}$ 的特征值为 λ_i ，特征向量为 $\mathbf{v}_i$ 。

1. **曲率解读：** λ_i 代表函数沿 $\mathbf{v}_i$ 方向的弯曲程度。 $|\lambda_i|$ 越大，函数在该方向变化越剧烈。
2. **局部地形判别：**
 - $\lambda_i > 0, \forall i \implies$ 极小值（正定矩阵）。
 - $\lambda_i < 0, \forall i \implies$ 极大值（负定矩阵）。
 - 存在异号特征值 $\implies$ 鞍点，这是高维优化中的常见陷阱。
3. **优化速度：** 最大特征值 $\lambda_{\max}$ 限制了梯度下降的最大允许步长；而特征值的分布范围（条件数）决定了问题的病态程度。牛顿法通过 $\mathbf{H}^{-1}$ 消除不同特征值方向上的量纲差异，使各方向以均匀速度收敛。

1.1.5 多元函数的凹凸性 (Convexity)

定义： 函数 f 为凸函数，若对于任意 x, y 和 $\lambda \in [0, 1]$ ：

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$

二阶判别法： 若 f 二阶可微且 Hessian 矩阵 $\mathbf{H}$ 半正定 ($\mathbf{H} \succeq 0$)，则 f 是凸函数。**重要性：** 在凸优化中，任何局部极小值都是全局最小值。这是 SVM、逻辑回归等线性模型易于训练的基础。

1.1.6 多元函数的泰勒公式

在机器学习优化算法的分析中，常使用二阶展开：

$$f(\mathbf{x} + \Delta \mathbf{x}) \approx f(\mathbf{x}) + \nabla f(\mathbf{x})^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \mathbf{H}(\mathbf{x}) \Delta \mathbf{x}$$

推导： 当我们使用学习率为 η 的梯度下降时， $\Delta \mathbf{x} = -\eta \nabla f$ 。代入展开式：

$$f(\mathbf{x} - \eta \nabla f) \approx f(\mathbf{x}) - \eta \|\nabla f\|^2 + \frac{\eta^2}{2} \nabla f^T \mathbf{H} \nabla f$$

为了确保函数值下降 ($f(\mathbf{x}_{new}) < f(\mathbf{x})$)，步长 η 必须足够小。

1.1.7 多重积分换元法与 Normalizing Flows

设 $\mathbf{x} = \mathbf{g}(\mathbf{z})$ 为一个可逆变换，根据概率密度转换公式：

$$p_x(\mathbf{x}) = p_z(\mathbf{z}) \left| \det \left(\frac{\partial \mathbf{g}}{\partial \mathbf{z}} \right) \right|^{-1} = p_z(\mathbf{z}) |\det \mathbf{J}_g(\mathbf{z})|^{-1}$$

这就是生成模型中“流模型 (Normalizing Flows)”的核心数学原理，通过雅可比行列式来计算复杂分布的概率密度。

1.2 高等代数

1.2.1 向量的范数 (Vector Norms)

范数用于度量向量的大小。常用的 L_p 范数定义为：

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

- L_1 范数： $\|\mathbf{x}\|_1 = \sum |x_i|$ ，在特征选择中产生稀疏解 (Lasso 回归)。
- L_2 范数： $\|\mathbf{x}\|_2 = \sqrt{\mathbf{x}^T \mathbf{x}}$ ，用于岭回归 (Ridge) 防止过拟合。
- L_∞ 范数： $\|\mathbf{x}\|_\infty = \max_i |x_i|$ ，常用于衡量对抗样本的最大扰动。

1.2.2 矩阵的范数与谱范数 (Matrix Norms)

矩阵范数衡量矩阵作为线性变换对向量产生的最大伸缩比例。

- **Frobenius 范数**： $\|\mathbf{A}\|_F = \sqrt{\sum_{i,j} a_{ij}^2}$ ，类似向量的 L_2 范数。
- **谱范数 (Spectral Norm)**： $\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A})$ ，即矩阵最大奇异值。

矩阵谱范数的推导 诱导 2-范数定义为 $\|\mathbf{A}\|_2 = \sup_{\|\mathbf{x}\|_2=1} \|\mathbf{A}\mathbf{x}\|_2$ 。推导如下：

$$\|\mathbf{A}\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} \quad (3)$$

由对称矩阵的特征值分解可知， $\mathbf{x}^T (\mathbf{A}^T \mathbf{A}) \mathbf{x}$ 的最大值对应其最大特征值 $\lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 。由于奇异值 σ_i 定义为 $\mathbf{A}^T \mathbf{A}$ 特征值的平方根，故：

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A}) \quad (4)$$

谱归一化 (Spectral Normalization) 实例 在 GANs 的训练中，为了满足 1-Lipschitz 约束，对每一层权重 $\mathbf{W}$ 执行：

$$\mathbf{W}_{SN} = \frac{\mathbf{W}}{\sigma_{\max}(\mathbf{W})} \quad (5)$$

由于 $\|\mathbf{W}_{SN}\|_2 = 1$ ，这保证了输入扰动在通过该层时不会被放大，从而稳定了判别器的梯度流。

矩阵范数的大小关系 对于秩为 r 的矩阵 $\mathbf{A} \in \mathbb{R}^{m \times n}$ ：

$$\|\mathbf{A}\|_2 \leq \|\mathbf{A}\|_F \leq \sqrt{r} \|\mathbf{A}\|_2 \quad (6)$$

F -范数关注矩阵的整体元素大小，而谱范数关注矩阵作为算子的最大拉伸能力。

1.2.3 Householder 变换与 QR 算法

Householder 变换是一种镜像反射变换： $\mathbf{H} = \mathbf{I} - 2\mathbf{v}\mathbf{v}^T$ ，其中 $\|\mathbf{v}\|_2 = 1$ 。

Householder 变换的构造与性质 定义 Householder 矩阵为 $\mathbf{H} = \mathbf{I} - 2\mathbf{v}\mathbf{v}^T$ ，其中 $\|\mathbf{v}\| = 1$ 。

- 对称正交性： $\mathbf{H} = \mathbf{H}^T = \mathbf{H}^{-1}$ ，即 $\mathbf{H}^2 = \mathbf{I}$ 。
- 几何消去：为了将向量 $\mathbf{x}$ 变换为 $\alpha\mathbf{e}_1$ ，选取 $\mathbf{v}$ 正比于 $\mathbf{x} - \text{sgn}(x_1)\|\mathbf{x}\|_2\mathbf{e}_1$ 。这种变换比 Gram-Schmidt 正交化具有更好的数值稳定性。

QR 分解与特征值迭代

1. **QR 分解**：任何实矩阵均可分解为 $\mathbf{A} = \mathbf{Q}\mathbf{R}$ 。在数值实现中，通常使用 Householder 反射实现，复杂度为 $O(n^3)$ 。
2. **QR 迭代算法**：通过反复进行 $\mathbf{A}_k = \mathbf{Q}_k\mathbf{R}_k \rightarrow \mathbf{A}_{k+1} = \mathbf{R}_k\mathbf{Q}_k$ 的相似变换，矩阵将收敛至 Schur 形式。这是现代计算机求解中大规模矩阵特征值的标准方法。代）。

QR 分解计算示例 (Householder 变换) 设待分解矩阵为 $\mathbf{A} = [3, 1; 4, 2; 0, 5]$ 。

1. **第一次反射**：选取 $\mathbf{v}_1 = \frac{1}{\sqrt{5}}[2, 1, 0]^T$ ，构造 $\mathbf{H}_1 = \mathbf{I} - 2\mathbf{v}_1\mathbf{v}_1^T$ 。计算得：

$$\mathbf{H}_1\mathbf{A} = \begin{bmatrix} -5 & -2.2 \\ 0 & 0.4 \\ 0 & 5 \end{bmatrix}$$

2. **第二次反射**：针对子矩阵的第二列元素 $[0.4, 5]^T$ 构造 $\mathbf{H}_2$ ，使得子矩阵首位下方元素清零。
3. **结果**： $\mathbf{R} = \mathbf{H}_2\mathbf{H}_1\mathbf{A}$ 为上三角矩阵， $\mathbf{Q} = \mathbf{H}_1\mathbf{H}_2$ 为正交矩阵（此处为 3×3 ）。

注：在机器学习的最小二乘问题中，直接利用 $\mathbf{R}$ 矩阵进行回代求解比求逆矩阵更稳定。

1.2.4 广义特征值与瑞利商 (Rayleigh Quotient)

广义特征值问题： $\mathbf{A}\mathbf{x} = \lambda\mathbf{B}\mathbf{x}$ 。**瑞利商**：对于对称矩阵 $\mathbf{A}$ ，定义 $R(\mathbf{A}, \mathbf{x}) = \frac{\mathbf{x}^T\mathbf{A}\mathbf{x}}{\mathbf{x}^T\mathbf{x}}$ 。

- **性质**：瑞利商的最大值和最小值分别对应 $\mathbf{A}$ 的最大和最小特征值。
- **机器学习应用**：在线性判别分析 (LDA) 中，我们的目标是最大化类间散度与类内散度的比值，这本质上是求解广义瑞利商。

1.2.5 矩阵的条件数 (Condition Number)

定义为 $\kappa(\mathbf{A}) = \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$ 。对于 L_2 范数， $\kappa(\mathbf{A}) = \frac{\sigma_{\max}}{\sigma_{\min}}$ 。

- **数值稳定性**：条件数越大，矩阵越接近奇异（病态）。在求解 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 时，输入的小扰动会被放大 $\kappa(\mathbf{A})$ 倍。正则化（如 Ridge）的本质就是通过减小矩阵的条件数来提升数值稳定性。

1.2.6 矩阵分解 (Matrix Decompositions)

- Cholesky 分解**: 若 $\mathbf{A}$ 是对称正定矩阵, 则可分解为 $\mathbf{A} = \mathbf{L}\mathbf{L}^T$, 其中 $\mathbf{L}$ 是下三角矩阵。应用: 高斯过程 (Gaussian Processes) 中采样和计算似然的核心步骤。
- QR 分解**: $\mathbf{A} = \mathbf{Q}\mathbf{R}$ 。应用: 求解线性最小二乘问题的数值稳定方法。
- 奇异值分解 (SVD)**: $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 。推导: $\mathbf{A}^T\mathbf{A} = \mathbf{V}\mathbf{\Sigma}^2\mathbf{V}^T$, 故 $\mathbf{V}$ 的列是 $\mathbf{A}^T\mathbf{A}$ 的特征向量。应用: 主成分分析 (PCA) 的数学实现, 通过保留前 k 个最大奇异值实现数据的最优低维嵌入。

1.3 概率论

1.3.1 条件独立性 (Conditional Independence)

定义: 给定随机变量 Z , 若 X 和 Y 满足:

$$p(X, Y|Z) = p(X|Z)p(Y|Z)$$

则称 X 与 Y 关于 Z 条件独立, 记作 $X \perp Y|Z$ 。

- 意义**: 这是概率图模型 (如贝叶斯网络) 的核心。它允许我们将复杂的联合分布分解为多个局部条件的乘积, 极大地减少了模型参数量。

1.3.2 Jensen 不等式 (Jensen's Inequality)

定义: 若 f 是凸函数, 则对于随机变量 X , 有:

$$f(E[X]) \leq E[f(X)]$$

若 f 是凹函数 (如 $\ln x$), 则不等号反向。

- 机器学习应用**: 它是变分推断 (Variational Inference) 和 EM 算法的数学基石。在推导 ELBO (证据下界) 时, 利用 $\ln E[p/q] \geq E[\ln p/q]$ 来寻找似然函数的下界。

1.3.3 典型概率分布

- 多项分布 (Multinomial)**: 二项分布的推广, 用于对类别特征 (Categorical features) 建模, 常配合 Softmax 函数使用。
- 拉普拉斯分布 (Laplace)**: $p(x) \propto \exp(-|x - \mu|/b)$ 。其在 0 处的尖峰特性对应 L_1 正则化, 能产生稀疏性。
- t 分布 (Student's t)**: 比正态分布有更厚的尾部 (Heavy-tailed)。在机器学习中用于构建对异常值鲁棒 (Robust) 的模型, 避免受噪声过度影响。

1.3.4 多维正态分布 (Multivariate Normal Distribution)

定义为:

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{n/2}|\mathbf{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \mathbf{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

- 几何意义**: 其等密度线是超椭球体, 形状由协方差矩阵 $\mathbf{\Sigma}$ 的特征值和特征向量决定。
- 应用**: 高斯混合模型 (GMM) 和高斯过程 (GP) 的基础。

1.3.5 概率分布变换 (Change of Variables)

设 $\mathbf{y} = \mathbf{f}(\mathbf{x})$ 且 $\mathbf{f}$ 为双射, 则 $\mathbf{y}$ 的概率密度为:

$$p_y(\mathbf{y}) = p_x(\mathbf{x}) \left| \det \left(\frac{\partial \mathbf{x}}{\partial \mathbf{y}} \right) \right|$$

这要求雅可比矩阵必须容易计算, 是实现 Normalizing Flows 的关键约束。

1.3.6 参数估计: MLE, MAP 与贝叶斯估计

假设数据集为 $\mathcal{D}$, 参数为 θ :

1. 最大似然估计 (MLE): $\theta_{MLE} = \arg \max_{\theta} p(\mathcal{D}|\theta)$ 。不考虑先验, 容易过拟合。
2. 最大后验估计 (MAP): $\theta_{MAP} = \arg \max_{\theta} p(\theta|\mathcal{D}) = \arg \max_{\theta} p(\mathcal{D}|\theta)p(\theta)$ 。相当于 MLE 加上正则化项。
3. 贝叶斯估计: 不计算单一的 θ 值, 而是计算完整的后验分布 $p(\theta|\mathcal{D})$ 。预测时通过全概率公式积分: $p(y^*|\mathcal{D}) = \int p(y^*|\theta)p(\theta|\mathcal{D})d\theta$ 。

1.3.7 随机数生成算法 (Sampling Methods)

当无法直接从复杂分布 $p(x)$ 中采样时:

- 逆变换采样 (Inverse Transform): 适用于已知累积分布函数 (CDF) $F(x)$ 的情况。令 $x = F^{-1}(u)$, 其中 $u \sim \text{Uniform}(0, 1)$ 。
- 拒绝采样 (Rejection Sampling): 引入提议分布 $q(x)$ 和常数 M 使得 $Mq(x) \geq p(x)$ 。采出的样本以比例 $p(x)/Mq(x)$ 被接受。

1.4 最优化方法 (机器学习算法的动力源泉)

1.4.1 基本概念与分类

机器学习中的优化问题通常表示为:

$$\min_{\mathbf{w} \in \mathcal{X}} \mathcal{L}(\mathbf{w}) = \frac{1}{n} \sum_{i=1}^n \ell(f(\mathbf{x}_i; \mathbf{w}), y_i) + \lambda R(\mathbf{w})$$

其中 $\mathcal{L}$ 为目标函数, ℓ 为损失函数, R 为正则化项。

- 无约束优化: $\mathcal{X} = \mathbb{R}^d$ 。
- 有约束优化: 包含等式或不等式约束。
- 凸优化: 目标函数和约束集均为凸。其核心性质是: 任何局部最优解都是全局最优解。

1.4.2 一阶优化方法: 梯度下降及其变体

梯度 $\nabla f(\mathbf{x})$ 是函数上升最快的方向, 因此下降方向取其负方向。

1. 梯度下降 (GD): $\mathbf{x}_{k+1} = \mathbf{x}_k - \eta \nabla f(\mathbf{x}_k)$ 。

2. **随机梯度下降 (SGD)**: 每次迭代仅随机抽取一个样本 (x_i, y_i) 计算梯度。推导: $E[\nabla f_i(\mathbf{x})] = \nabla f(\mathbf{x})$, 即随机梯度的期望是真实梯度。噪声有助于逃离鞍点。

3. **动量法 (Momentum)**: 引入一阶累积:

$$\begin{cases} \mathbf{v}_t = \gamma \mathbf{v}_{t-1} + \eta \nabla f(\mathbf{x}_t) \\ \mathbf{x}_{t+1} = \mathbf{x}_t - \mathbf{v}_t \end{cases}$$

这在物理上模拟了物体下山的惯性, 能抑制震荡并加速通过平坦区域。

1.4.3 二阶优化方法: 利用曲率信息

牛顿法 (Newton's Method): 对 $f(\mathbf{x})$ 在 $\mathbf{x}_k$ 处进行二阶泰勒展开:

$$f(\mathbf{x}) \approx f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^T (\mathbf{x} - \mathbf{x}_k) + \frac{1}{2} (\mathbf{x} - \mathbf{x}_k)^T \mathbf{H}_k (\mathbf{x} - \mathbf{x}_k)$$

令上式对 $\mathbf{x}$ 的导数为 0, 得:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \mathbf{H}_k^{-1} \nabla f(\mathbf{x}_k)$$

评价: 牛顿法具有二阶收敛性, 但计算 $d \times d$ 的 Hessian 矩阵及其逆的开销为 $O(d^3)$, 在深度学习中几乎无法使用。

1.4.4 带约束的优化: 拉格朗日对偶性

考虑标准约束问题:

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad g_i(\mathbf{x}) \leq 0, \quad h_j(\mathbf{x}) = 0$$

定义拉格朗日函数:

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\mathbf{x}) + \sum_i \lambda_i g_i(\mathbf{x}) + \sum_j \nu_j h_j(\mathbf{x}) \quad (\lambda_i \geq 0)$$

推导步骤: 1. **原始问题 (Primal)**: $\min_{\mathbf{x}} \max_{\boldsymbol{\lambda}, \boldsymbol{\nu}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 。若 $\mathbf{x}$ 违反约束, 则内层 $\max$ 会趋向 $+\infty$ 。2. **对偶问题 (Dual)**: $\max_{\boldsymbol{\lambda}, \boldsymbol{\nu}} \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\nu})$ 。3. **强对偶性 (Strong Duality)**: 若满足 Slater 条件 (即存在一点使不等式约束严格成立), 则 $d^* = p^*$ 。

KKT 条件 (必要条件): 若 $\mathbf{x}^*$ 是局部最优解, 则存在 $\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*$ 满足:

- $\nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\nu}^*) = 0$ (驻点条件)
- $g_i(\mathbf{x}^*) \leq 0, \quad h_j(\mathbf{x}^*) = 0$ (原始可行性)
- $\lambda_i^* \geq 0$ (对偶可行性)
- $\lambda_i^* g_i(\mathbf{x}^*) = 0$ (互补松弛性) ——这解释了 SVM 中为何只有支持向量对应的 $\lambda_i > 0$ 。

1.4.5 针对特殊结构的优化算法

1. **近端梯度下降法 (Proximal Gradient Descent)** 在机器学习中, 目标函数常具有 $f(\mathbf{x}) + g(\mathbf{x})$ 的形式, 其中 f 是平滑的 (如均方误差), 而 g 是非平滑但凸的 (如 L_1 范数 $\|\mathbf{x}\|_1$)。

- **核心思想**: 并不直接对 g 求导, 而是利用近端算子 (Proximal Operator):

$$\text{prox}_{\eta g}(\mathbf{z}) = \arg \min_{\mathbf{x}} \left(g(\mathbf{x}) + \frac{1}{2\eta} \|\mathbf{x} - \mathbf{z}\|_2^2 \right)$$

- 迭代步骤:

$$\mathbf{x}_{k+1} = \text{prox}_{\eta g}(\mathbf{x}_k - \eta \nabla f(\mathbf{x}_k))$$

- 实例 (ISTA): 当 $g(\mathbf{x}) = \lambda \|\mathbf{x}\|_1$ 时, 近端算子即为软阈值算子。这是求解 Lasso 回归的标准算法。

2. 交替方向乘子法 (ADMM) ADMM 旨在结合拉格朗日乘子法的收敛性和坐标下降法的分解性。适用于如下问题:

$$\min f(\mathbf{x}) + g(\mathbf{z}) \quad \text{s.t.} \quad \mathbf{Ax} + \mathbf{Bz} = \mathbf{c}$$

- 增广拉格朗日函数:

$$L_\rho(\mathbf{x}, \mathbf{z}, \mathbf{u}) = f(\mathbf{x}) + g(\mathbf{z}) + \mathbf{u}^T(\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}) + \frac{\rho}{2} \|\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}\|_2^2$$

- 迭代推导: 交替固定 $\mathbf{z}$ 优化 $\mathbf{x}$, 固定 $\mathbf{x}$ 优化 $\mathbf{z}$, 最后更新对偶变量 $\mathbf{u}$ 。
- 意义: 它将复杂问题拆解为多个子问题, 是分布式机器学习 (如联邦学习) 的数学基石。

3. 坐标下降法 (Coordinate Descent)

- 原理: 每次迭代只更新一个维度 x_i , 而保持其他维度固定。
- 推导: 解 $\frac{\partial f}{\partial x_i} = 0$ 得到 x_i 的更新方程。
- 应用: 支持向量机 (SVM) 中的 SMO 算法 便是坐标下降的一种特殊形式 (由于约束存在, 每次更新两个变量)。

1.4.6 深度学习中的自适应优化器

在非凸的高维空间中, 不同参数的梯度量级差异巨大。

1. AdaGrad: 累积历史梯度的平方, 并以此缩放学习率。使得稀疏特征对应的参数能获得更大的更新。
2. RMSProp: 引入指数衰减平均, 解决了 AdaGrad 后期学习率消失的问题:

$$E[g^2]_t = 0.9E[g^2]_{t-1} + 0.1g_t^2$$

3. Adam (Adaptive Moment Estimation): 同时结合了动量 (Momentum) 和 RMSProp:

- 一阶矩 (均值): $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$
- 二阶矩 (非中心方差): $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$
- 偏差修正: $\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$, $\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$
- 更新: $\Delta \theta = -\frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$

1.4.7 二阶近似: 拟牛顿法 (L-BFGS)

- 背景: 真正的牛顿法需要 $O(d^3)$ 的求逆开销。
- BFGS: 通过迭代构造一个矩阵 $\mathbf{B}_k$ 来逼近 Hessian 矩阵 $\mathbf{H}$, 只需满足割线方程 $s_k = \mathbf{B}_{k+1} y_k$ 。
- L-BFGS: “Limited-memory” 版本, 只存储最近 m 次的更新向量, 将存储空间从 $O(d^2)$ 降低到 $O(md)$ 。在传统机器学习大规模逻辑回归中表现卓越。

1.5 信息论 (Information Theory)

1.5.1 熵与自信息 (Entropy & Self-information)

自信息： 度量一个事件 x 发生时所携带的信息量。

$$I(x) = -\ln P(x)$$

小概率事件发生时，提供的信息量更大。

信息熵 (Entropy)： 随机变量不确定性的度量，即自信息的期望值。

$$H(X) = E_{x \sim P}[I(x)] = - \sum_{x \in \mathcal{X}} P(x) \log P(x)$$

对于连续变量，称为**微分熵**： $H(X) = - \int p(x) \log p(x) dx$ 。

- **性质：** 均匀分布具有最大的熵（不确定性最高）。

1.5.2 联合熵与条件熵 (Joint & Conditional Entropy)

条件熵： 在已知 Y 的情况下， X 的剩余不确定性。

$$H(X|Y) = \sum_{y \in \mathcal{Y}} P(y) H(X|Y=y) = - \sum_{x,y} P(x,y) \log P(x|y)$$

链式法则： $H(X,Y) = H(Y) + H(X|Y)$ 。

1.5.3 互信息 (Mutual Information)

度量两个随机变量之间的相关性，即已知 Y 的信息后， X 不确定性减少的量。

$$I(X;Y) = H(X) - H(X|Y) = \sum_{x,y} P(x,y) \log \frac{P(x,y)}{P(x)P(y)}$$

- **应用：** 特征选择中常利用互信息来衡量特征与标签之间的关联强度。

1.5.4 相对熵 (KL 散度)

定义： 衡量两个概率分布 P 和 Q 之间的差异。

$$D_{KL}(P||Q) = E_{x \sim P} \left[\log \frac{P(x)}{Q(x)} \right] = \sum_x P(x) \log \frac{P(x)}{Q(x)}$$

- **非对称性：** $D_{KL}(P||Q) \neq D_{KL}(Q||P)$ 。
- **非负性：** $D_{KL}(P||Q) \geq 0$ ，当且仅当 $P = Q$ 时取等号（Gibbs 不等式）。
- **变分推断：** 在 VI 中，我们通过最小化 KL 散度使近似分布 Q 逼近真实的后验分布 P 。

1.5.5 交叉熵 (Cross-Entropy)

在机器学习分类任务中，我们通常最小化交叉熵。

$$H(P,Q) = H(P) + D_{KL}(P||Q) = - \sum_x P(x) \log Q(x)$$

其中 P 是真实分布（通常是 one-hot 编码）， Q 是模型预测分布。

- **推导：** 由于真实分布 P 的熵 $H(P)$ 是常数，最小化交叉熵等价于最小化 P 和 Q 之间的 KL 散度。

1.5.6 最大熵原理 (Principle of Maximum Entropy)

在满足已知约束的情况下，应该选择熵最大的分布。

- **推导结论：** 1. 无约束下，熵最大的分布是均匀分布。2. 均值和方差固定时，熵最大的分布是正态分布（高斯分布）。3. 逻辑回归本质上是满足经验分布约束下的最大熵模型。

1.6 随机过程 (Stochastic Processes)

1.6.1 基本概念

随机过程 $\{X(t), t \in T\}$ 是定义在概率空间上的随机变量族。对于每一个固定的 t ， $X(t)$ 是一个随机变量；对于每一个固定的样本点 ω ， $X(t, \omega)$ 是关于时间 t 的函数，称为**样本轨道**。

1.6.2 平稳过程 (Stationary Processes)

- **严平稳：** 任意有限维分布在时间平移下保持不变。
- **宽平稳 (WSS)：** 1. 均值函数 $E[X(t)] = \mu$ 为常数。2. 自相关函数 $R_X(t, t + \tau) = E[X(t)X(t + \tau)]$ 仅与时间间隔 τ 有关。

1.6.3 马尔可夫过程 (Markov Processes)

马尔可夫性（无后效性）： 给定当前状态，系统的未来状态与过去状态无关。

$$P(X_{n+1} = x_{n+1} | X_1 = x_1, \dots, X_n = x_n) = P(X_{n+1} = x_{n+1} | X_n = x_n)$$

- **转移概率矩阵 $\mathbf{P}$ ：** $P_{ij} = P(X_{n+1} = j | X_n = i)$ 。
- **平稳分布 π ：** 若满足 $\pi \mathbf{P} = \pi$ ，则称 π 为该链的平稳分布。
- **应用：** MCMC（马尔可夫链蒙特卡洛）采样，通过构造特定转移矩阵使平稳分布恰好为目标分布。

1.6.4 高斯过程 (Gaussian Processes, GP)

定义： 若随机过程的任意有限个观测点的联合分布都服从多元正态分布，则称其为高斯过程。

$$X(t) \sim \mathcal{GP}(m(t), \kappa(t, t'))$$

- **核函数 (Kernel)：** $\kappa(t, t')$ 定义了样本点之间的相关性（平滑度）。
- **贝叶斯优化：** 利用 GP 作为替代模型 (Surrogate model) 来寻找超参数的最优解。

1.6.5 维纳过程与布朗运动 (Wiener Process)

维纳过程 $W(t)$ 是连续随机过程的基石，满足：1. $W(0) = 0$ 。2. 独立增量： $W(t+s) - W(t) \sim \mathcal{N}(0, s)$ 。3. 样本轨道几乎处处连续但处处不可微。

- **应用：** 它是随机微分方程 (SDE) 的驱动项，也是当前热门的 **生成扩散模型 (Diffusion Models)** 的物理原型（前向加噪过程）。

1.6.6 泊松过程 (Poisson Process)

用于建模随机事件在时间轴上的计数。

$$P(N(t) = k) = \frac{(\lambda t)^k e^{-\lambda t}}{k!}$$

其特点是事件发生的独立性和无记忆性，常用于排队论及强化学习中的稀疏奖励建模。

1.6.7 随机微分方程 (SDE) 简介

在生成模型中，常用的朗之万动力学 (Langevin Dynamics) 可表示为：

$$d\mathbf{x}_t = \mathbf{f}(\mathbf{x}_t, t)dt + \mathbf{g}(t)d\mathbf{W}_t$$

这里 $d\mathbf{W}_t$ 代表维纳过程的增量。扩散模型通过反向求解此类方程，实现将白噪声还原为高质量图像。

2 机器学习基础 (Machine Learning Basics)

基本流程：

数据 $\Rightarrow$ 机器学习算法 $\Rightarrow$ 规律 $\Rightarrow$ 预测未知数据

- **训练集 (Training Set):** $D_{train} = \{(\underline{x}^{(1)}, y^{(1)}), (\underline{x}^{(2)}, y^{(2)}), \dots, (\underline{x}^{(m)}, y^{(m)})\}$
 - $\underline{x}^{(i)}$: 特征 (Feature)
 - $y^{(i)}$: 真实值 (Ground Truth)
- **测试集 (Test Set):** $D_{test} = \{(\underline{x}^{(j)}, \hat{y}^{(j)})\}$
- **要求:** $D_{train} \cap D_{test} = \emptyset$

预测类型：

- **回归 (Regression):** 连续型输出
- **分类 (Classification):** 离散型输出

学习范式：

- **监督学习 (Supervised Learning):** 提供 Ground Truth。
- **无监督学习 (Unsupervised Learning):** 不提供 Ground Truth。

3 线性回归模型 (Linear Regression Model)

模型假设 (Hypothesis):

$$y = h_{\theta}(\underline{x}) = \underline{\theta}^T \underline{x} = \theta_0 + \theta_1 x_1 + \dots + \theta_n x_n$$

向量表示：

$$\underline{\theta} = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_n \end{bmatrix}, \quad \underline{x} = \begin{bmatrix} 1 \\ x_1 \\ \vdots \\ x_n \end{bmatrix}$$

3.1 评价指标与损失函数

- 均方误差 (MSE):

$$MSE = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(\underline{x}^{(i)}) - y^{(i)})^2$$

- 损失函数 (Loss Function):

$$J(\theta) = \text{MSE} = \frac{1}{m} \sum_{i=1}^m (\theta^T \underline{x}^{(i)} - y^{(i)})^2$$

3.2 求解方法

1. 解析解 (Normal Equation):

$$\underline{\theta}^* = (X^T X)^{-1} X^T \underline{y}$$

2. 梯度下降法 (Gradient Descent):

- 梯度: $\nabla J(\underline{\theta}) = \left[\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1}, \dots, \frac{\partial J}{\partial \theta_n} \right]^T$
- 更新规则: $\underline{\theta} := \underline{\theta} - \alpha \nabla J(\underline{\theta})$
- 超参数: α 为学习率 (Learning Rate)。若 α 过大, 梯度会产生震荡。

4 逻辑回归 (Logistic Regression)

分类任务: $y \in \{0, 1\}$ (二分类) 或 $y \in \{1, \dots, C\}$ (多分类)。

Sigmoid 函数 (激活函数):

$$h_{\theta}(\underline{x}) = \frac{1}{1 + e^{-\theta^T \underline{x}}}$$

决策阈值:

$$y = \begin{cases} 1, & h_{\theta}(\underline{x}) \geq 0.5 \\ 0, & h_{\theta}(\underline{x}) < 0.5 \end{cases}$$

交叉熵损失函数 (Loss Function):

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m [-y^{(i)} \log(h_{\theta}(\underline{x}^{(i)})) - (1 - y^{(i)}) \log(1 - h_{\theta}(\underline{x}^{(i)}))]$$




图 2.2 机器学习系统示例

图 1: Location of Tokyo Tower