

论文笔记：K-均值聚类的分层初始化方法

(Hierarchical Initialization for K-Means)

2026 年 1 月 26 日

1 核心思想与背景

该方法将聚类问题转化为**加权聚类问题**。通过类似金字塔结构的自底向上采样减少数据规模，在高层寻找初始中心，再自顶向下逐层精炼。

2 数学准备与关键性质

2.1 加权采样定义 (2D 示例)

设第 k 层有 4 个相邻点 (i, j) ，其权值为 $w_{k,i,j}$ 。采样到第 $k+1$ 层后，产生新点 $P(P_x, P_y, P_w)$ ：

- 坐标映射： $P_x = \frac{i+1}{2}, P_y = \frac{j+1}{2}$ [cite: 519]。
- 权重计算： $P_w = \frac{w_{k,i,j} + w_{k,i+1,j} + w_{k,i,j+1} + w_{k,i+1,j+1}}{4}$ 。

2.2 核心理论性质

性质 1 (质心性质)。对于加权密度聚类，若使用平方误差准则，聚类中心即为其加权质心。

性质 2 (投影误差界限)。设 X_{k+1} 为第 $k+1$ 层中心， X_k 为第 k 层对应中心，则满足：

$$2 \cdot X_{k+1} - X_k \leq 1 \quad (1)$$

该性质证明了高层中心投影回底层后，距离真实最优中心极近（误差 ≤ 1 ），保证了极快的收敛速度。

2.3 性质 2 的证明 (Proof of Property 2)

证明目标：证明 $0 \leq 2 \cdot X_{k+1,j} - X_{k,j} \leq 1$ 。

Proof. 1. 定义两层质心坐标：根据性质 1，第 $k+1$ 层某簇 j 的质心坐标为：

$$X_{k+1,j} = \frac{\sum_{m=1}^n W_{k+1,m} x_{k+1,m}}{\sum_{m=1}^n W_{k+1,m}} \quad (2)$$

对应的第 k 层质心坐标为：

$$X_{k,j} = \frac{\sum_{l=1}^{4n} w_{k,l} x_{k,l}}{\sum_{l=1}^{4n} w_{k,l}} \quad (3)$$

2. 统一坐标系: 为了比较, 将 $X_{k+1,j}$ 投影回第 k 层 (坐标乘以 2), 计算差值:

$$\Delta = 2 \cdot X_{k+1,j} - X_{k,j} = \frac{2 \cdot \sum_{m=1}^n W_{k+1,m} x_{k+1,m}}{\sum_{m=1}^n W_{k+1,m}} - \frac{\sum_{l=1}^{4n} w_{k,l} x_{k,l}}{\sum_{l=1}^{4n} w_{k,l}} \quad (4)$$

3. 权重代换: 设第 k 层所有相关点的权重总和为 $T = \sum w_{k,l}$, 第 $k+1$ 层为 $S = \sum W_{k+1,m}$ 。由于 $W_{k+1,m} = \frac{w_{k,i} + w_{k,i+1} + w_{k,j} + w_{k,j+1}}{4}$, 易证 $T = 4S$ 。由此可将差值公式简化为:

$$\Delta = \frac{8 \cdot \sum_{m=1}^n W_{k+1,m} x_{k+1,m} - \sum_{l=1}^{4n} w_{k,l} x_{k,l}}{T} \quad (5)$$

4. 单点分析: 考虑第 $k+1$ 层的一个点及其对应的第 k 层四个点 (坐标分别为 $i, i+1$)。第 $k+1$ 层项贡献为: $8 \cdot W_{k+1,m} \cdot \frac{i+1}{2} = (w_{k,i,j} + w_{k,i+1,j} + w_{k,i,j+1} + w_{k,i+1,j+1})(i+1)$ 。第 k 层项贡献为: $w_{k,i,j} \cdot i + w_{k,i+1,j}(i+1) + w_{k,i,j+1} \cdot i + w_{k,i+1,j+1}(i+1)$ 。两者相减得:

$$\text{分子单项差} = w_{k,i,j} + w_{k,i,j+1} \quad (6)$$

5. 结论: 将所有点累加, 分子变为部分原始权重的和, 而分母 T 是所有权重的和。由于权重 $w \geq 0$, 显然有:

$$0 \leq \frac{\sum (w_{k,i,j} + w_{k,i,j+1})}{T} \leq 1 \quad (7)$$

证毕。 $\square$

3 算法详细流程

分层初始化算法步骤

Step 0: 预处理 将数据坐标线性映射为 $1 \dots 2^N$ 的整数。

Step 1: 自底向上采样 重复执行平均采样, 直到数据量减小至 $\geq 20 \cdot C_{num}$ (即簇数的 20 倍)。

Step 2: 顶层初始化 排序策略: 选取权值最大的 C_{num} 个点作为初始中心。此举利用了采样过程的“平滑效应”来抑制噪声。

Step 3: 自顶向下精炼 将 $k+1$ 层中心坐标翻倍投影至 k 层, 作为初始值进行迭代, 直至回到原始层。

Step 4: 后处理 执行逆变换回到原始坐标空间。

4 高维情况处理 ($D > 2$)

针对高维数据的稀疏性, 算法进行了以下优化:

- **存储优化:** 不使用全空间网格, 仅使用 $N \times D$ 数组存储非零点。
- **权重合并:** 采样后, 若不同原始点映射到了相同的整数坐标, 则将其权值累加。
- **权值衰减:** 高维采样时, 单点权值需除以 2^D 。

5 实验结论与性能对比

- **时间效率：**在 Iris 和 Glass 数据集上，由于初始化极佳，每一层迭代通常少于 10 次。总运行时间显著低于 KA 方法和 Fayyad 的随机采样法。
- **抗噪性：**采样过程类似于低通滤波器，能有效识别数据“峰值”并抑制分布均匀的噪声。
- **局限性：**实验表明，在维度较低时（ < 10 维）优于 Fayyad 法；但在极高维度下，性能可能略逊于 Fayyad 法。