




MATHEMATICAL STATISTICS




数理统计

学习 笔记

魏舟

2025 年 12 月 1 日



” 相关不等于因果。 ”

目录

第 1 章 基本概念	3
1.1 总体、样本与统计量	3
1.1.1 总体与样本	3
1.1.2 统计量	4
1.2 常用统计量的分布（抽样分布）	6
1.2.1 χ^2 分布	6
1.2.2 t 分布	8
1.2.3 F 分布	10
1.3 正态总体下的三大抽样定理	11
1.3.1 附加重要结论	12
第 2 章 参数估计	13
2.1 参数估计的概念	13
2.2 矩估计法（简称“矩法”）	14
2.3 极大似然估计法	15
2.4 估计量的评选标准	18
2.4.1 无偏性	18
2.4.2 有效性	18
2.4.3 一致性	19
2.4.4 附加例题（最优无偏估计）	19
2.5 区间估计	20
2.5.1 概念	20
2.5.2 正态总体的抽样分布定理（枢轴量）	20
2.5.3 正态总体参数的区间估计	21

第 3 章 假设检验	23
3.1 假设检验的基本概念和思想	23
3.1.1 原假设与备择假设	23
3.1.2 检验法则与拒绝域	24
3.1.3 检验的两种错误	25
3.1.4 显著性检验的基本步骤	26
3.2 单个正态总体的假设检验	26
3.2.1 单个正态总体均值的假设检验	26
3.2.2 单个总体方差的假设检验	27
3.3 双正态总体均值与方差比的假设检验	27
3.3.1 均值差的假设检验	27
3.3.2 方差比的假设检验	28

前言

本笔记由我的《数理统计》课堂笔记整理而成。

基本概念

§ 1.1 总体、样本与统计量

1.1.1 总体与样本

定义 1.1 (总体)

研究对象的全体。通常指研究对象的某项数量指标。组成总体的元素称为个体。从本质上讲，总体就是所研究的随机变量或随机变量的分布。

定义 1.2 (样本 (简单随机样本))

来自总体的部分个体 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 。如果满足:

1. 同分布性: $\mathbf{X}_i$ ($i = 1, \dots, n$) 与总体同分布。
2. 独立性: $\mathbf{X}_1, \dots, \mathbf{X}_n$ 相互独立。

则称为容量为 n 的简单随机样本, 简称样本。而称 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 的一次实现为样本观察值, 记为 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 。

来自总体 X 的随机样本 $\mathbf{X}_1, \dots, \mathbf{X}_n$ 可记为

$$X_1, \dots, X_n \stackrel{iid}{\sim} X \quad \text{或} \quad f(x), F(x), \dots \quad (1.1)$$

显然, 样本联合分布函数或密度函数为

$$F^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i) \quad (1.2)$$

或

$$f^*(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i) \quad (1.3)$$

1.1.2 统计量**定义 1.3 (统计量)**

称样本 $X_1, \dots, X_n$ 的函数 $g(X_1, \dots, X_n)$ 是总体 X 的一个统计量, 如果 $g(X_1, \dots, X_n)$ 不含未知参数。

性质 1.4 (几个常用的统计量)

1. 样本均值 (Sample Mean):

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad (1.4)$$

2. 样本方差 (Sample Variance):

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad (1.5)$$

注意: 这里的系数是 $\frac{1}{n-1}$ 而不是 $\frac{1}{n}$, 这是为了保证它是无偏估计量。

3. 样本均方差 (标准差, Sample Standard Deviation):

$$S = \sqrt{S^2} \quad (1.6)$$

4. 样本 k 阶矩:

- 样本原点矩 (Sample Moment about Origin):

$$\frac{1}{n} \sum_{i=1}^n X_i^k \quad (1.7)$$

注: 当 $k = 1$ 时, 这就是样本均值。

- 样本中心矩 (Sample Central Moment):

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k \quad (1.8)$$

注: 当 $k = 2$ 时, 这对应于样本方差的某种形式, 但通常样本方差分母为 $n - 1$ 。

5. 经验分布函数 (Empirical Distribution Function): 用 $S(x)$ 表示样本 $X_1, \dots, X_n$ 中不大于 x 的随机变量个数, 定义经验分布函数 $F_n(x)$ 为:

$$F_n(x) = \frac{1}{n} S(x) \quad (1.9)$$

§ 1.2 常用统计量的分布（抽样分布）

1.2.1 χ^2 分布

定义 1.5 (χ^2 分布（构造）)

设 $X_1, \dots, X_n$ 独立同分布于标准正态分布，即 $X_1, \dots, X_n \stackrel{iid}{\sim} N(0, 1)$ ，则定义统计量

$$\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n) \quad (1.10)$$


称为自由度为 n 的 χ^2 分布。其概率密度函数为：

$$f(y) = \begin{cases} \frac{1}{2^{n/2}\Gamma(n/2)} y^{\frac{n}{2}-1} e^{-\frac{y}{2}}, & y > 0 \\ 0, & y \leq 0 \end{cases} \quad (1.11)$$

其中 $\Gamma(\cdot)$ 是伽马函数。

笔记要点

χ^2 分布本质上就是 n 个独立的标准正态随机变量的平方和。分布是非对称的（右偏），取值恒为正。随着自由度 n 的增大，曲线峰值向右移动，且图形逐渐趋向于对称（正态分布）。




定义 1.6（上 α 分位点）

设 $X \sim \chi^2(n)$ ，若对于 $\alpha: 0 < \alpha < 1$ ，存在 $\chi_\alpha^2(n) > 0$ 满足：

$$P\{X \geq \chi_\alpha^2(n)\} = \alpha \quad (1.12)$$

则称 $\chi_\alpha^2(n)$ 为 $\chi^2(n)$ 分布的**上 α 分位点**（Upper α quantile）。

**图示说明与举例**

- 图中阴影部分的面积为 α （右尾概率）。
- $\chi_\alpha^2(n)$ 是横轴上的临界值。
- $\chi_{0.05}^2(10) = 18.307$ （表示自由度为 10 时，大于 18.307 的概率是 0.05）
- $\chi_{0.95}^2(10) = 3.940$ （表示自由度为 10 时，大于 3.940 的概率是 0.95）

性质 1.7 (χ^2 分布的性质)

(a) 分布可加性 (Additivity): 若 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, 且 X, Y 相互独立, 则它们的和服从自由度相加的 χ^2 分布:

$$X + Y \sim \chi^2(n_1 + n_2) \quad (1.13)$$

(b) 期望与方差 (Expectation and Variance): 若 $X \sim \chi^2(n)$, 则

- 期望: $E(X) = n$
- 方差: $D(X) = 2n$ (记忆技巧: 期望等于自由度, 方差等于两倍自由度)

1.2.2 t 分布**定义 1.8 (t 分布 (构造))**

这是 t 分布最经典的定义方式, 一定要背下来:

- 设 $\xi \sim N(0, 1)$ (ξ 是标准正态分布)
- 设 $\eta \sim \chi^2(n)$ (η 是自由度为 n 的卡方分布)
- 且 ξ 与 η 相互独立

则构造出的统计量 T 为:

$$T = \frac{\xi}{\sqrt{\eta/n}} \sim t(n) \quad (1.14)$$


称 $t(n)$ 为自由度为 n 的 t 分布。其概率密度为:

$$f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi} \Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad -\infty < t < \infty \quad (1.15)$$

其中 $\Gamma(\cdot)$ 是伽马函数 (Gamma Function, 欧拉第二积分), 它是阶乘在实数域上的推广; $\left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$ 是函数的主体部分, 决定了 t 分布呈钟形曲线, 且比正态分布下降得更慢 (即 “厚尾”)。

t 分布的直观理解

- 分子是一个标准正态变量。
- 分母是一个调整后的卡方变量的平方根（起到了“归一化”或“缩放”的作用）。
- 当样本量 $n \rightarrow \infty$ 时， t 分布会收敛于标准正态分布 $N(0,1)$ 。但在小样本下， t 分布的尾部比正态分布更“厚”（更平坦），这使得它在小样本估计中更为保守和准确。

性质 1.9（ t 分布的基本性质）

1. 对称性： $f(t)$ 关于 $t = 0$ （纵轴）对称。
2. 极限性质：当自由度 $n \rightarrow \infty$ 时， $f(t)$ 的极限是标准正态分布 $N(0,1)$ 的密度函数，即

$$\lim_{n \rightarrow \infty} f(t) = \varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}, \quad -\infty < t < \infty \quad (1.16)$$

定义 1.10（ t 分布的分位点）

设 $T \sim t(n)$ ，若对于 $\alpha: 0 < \alpha < 1$ ，存在 $t_\alpha(n)$ ，满足：

$$P\{T \geq t_\alpha(n)\} = \alpha \quad (1.17)$$

则称 $t_\alpha(n)$ 为 $t(n)$ 分布的上侧 α 分位点。

重点性质：分位点的对称性

由于 t 分布关于 $t = 0$ 对称，因此

$$t_{1-\alpha}(n) = -t_{\alpha}(n) \quad (1.18)$$

示例： $t_{0.01}(20) = 2.5280$ ； $t_{0.99}(20) = t_{1-0.01}(20) = -t_{0.01}(20) = -2.5280$ 。

1.2.3 F 分布**定义 1.11 (F 分布 (构造))**

F 分布是通过两个独立的卡方 (χ^2) 随机变量的比值构造而成的。设 η_1 和 η_2 是两个独立的卡方随机变量，其自由度分别为 n_1 和 n_2 ：

- $\eta_1 \sim \chi^2(n_1)$

- $\eta_2 \sim \chi^2(n_2)$

则随机变量 F 的构造如下：

$$F = \frac{\eta_1/n_1}{\eta_2/n_2} \sim F(n_1, n_2) \quad (1.19)$$

自由度： n_1 称为**第一自由度**（分子自由度）， n_2 称为**第二自由度**（分母自由度）。其概率密度函数 $h(y)$ 如下（其中 Γ 是伽马函数）：

$$h(y) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right) (n_1/n_2)^{n_1/2}}{\Gamma\left(\frac{n_1}{2}\right) \Gamma\left(\frac{n_2}{2}\right)} \cdot \frac{y^{\frac{n_1}{2}-1}}{\left(1 + \frac{n_1}{n_2}y\right)^{(n_1+n_2)/2}}, & y > 0 \\ 0, & y \leq 0 \end{cases} \quad (1.20)$$

定义 1.12 (F 分布的分位点)

对于一个概率 α ($0 < \alpha < 1$)，如果存在一个正数 $F_{\alpha}(n_1, n_2)$ ，使得随机变量 F 大于或等于该值的概率恰好是 α ，则称 $F_{\alpha}(n_1, n_2)$ 为 $F(n_1, n_2)$ 分布的上侧 α 分位点。

$$P\{F \geq F_{\alpha}(n_1, n_2)\} = \alpha \quad (1.21)$$

分位点的重要性质

下侧分位点与上侧分位点之间的关系：

$$F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)} \quad (1.22)$$

§ 1.3 正态总体下的三大抽样定理

定理 1.13（标准化样本均值的分布（ U 统计量））

当总体方差 σ^2 已知时，标准化后的样本均值服从标准正态分布 $N(0, 1)$ 。

$$U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (1.23)$$

用途：用于总体均值 μ 的大样本检验，或 σ^2 已知时的单样本检验。

定理 1.14（样本方差的分布（ χ^2 统计量））

将样本方差 S^2 乘以适当的系数后，服从自由度为 $n - 1$ 的 χ^2 分布（卡方分布）。

$$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1) \quad (1.24)$$

用途：用于总体方差 σ^2 的估计和检验。

定理 1.15（ t 统计量的分布（小样本下的均值检验））

当总体方差 σ^2 未知时，使用样本标准差 S 替代 σ 对 $\bar{X}$ 进行标准化，得到的统计量服从自由度为 $n - 1$ 的 t 分布。

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1) \quad (1.25)$$

用途：用于总体均值 μ 的小样本检验，或 σ^2 未知时的单样本检验。

1.3.1 附加重要结论

正态总体下的附加重要结论

独立性结论：在正态总体下，样本均值 $\bar{X}$ 与样本方差 S^2 相互独立。（这是构建 T 统计量的关键，因为 T 统计量的构造要求分子（ U ）和分母的平方根（ $\sqrt{\chi^2/n}$ ）相互独立。）

延伸：两个正态总体的方差比（ F 统计量）： F 分布是这三大定理的自然延伸，它用于比较两个独立正态总体的方差。设有两个独立样本，来自 $N(\mu_1, \sigma_1^2)$ 和 $N(\mu_2, \sigma_2^2)$ ：

$$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1) \quad (1.26)$$

用途：用于检验两个总体的方差是否相等（即检验 $H_0 : \sigma_1^2 = \sigma_2^2$ ）。

参数估计

§ 2.1 参数估计的概念

定义 2.1 (估计量与点估计)

设 $X_1, \dots, X_n$ 是总体 X 的一个样本, 其分布函数为 $F(x; \theta)$, 其中 $\theta \in \Theta$ 为未知参数, Θ 为参数空间。若统计量 $g(X_1, \dots, X_n)$ 可作为 θ 的一个估计, 则称其为 θ 的估计量, 记为 $\hat{\theta}$ 。

- 公式: $\hat{\theta} = g(X_1, \dots, X_n)$ 。
- 注: $F(x; \theta)$ 也可用分布律或密度函数代替。
- 估计值: 若 $x_1, \dots, x_n$ 是样本的一个观测值, 则 $\hat{\theta} = g(x_1, \dots, x_n)$ 称为 θ 的估计值。
- 点估计: 由于 $\hat{\theta}$ 的估计值是一个实数域上的点, 故称这种估计为点估计。
- 经典方法: 点估计的经典方法是矩估计法与极大似然估计法。

§ 2.2 矩估计法 (简称“矩法”)

定理 2.2 (矩估计法)

1. 用样本矩作为总体同阶矩的估计:

$$E(\hat{X}^k) = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (2.1)$$

2. 若 $\hat{\theta}$ 是 θ 的矩估计, 则 $g(\theta)$ 的矩估计为 $g(\hat{\theta})$ 。

例题 2.3 (二项分布 $B(m, p)$: 求 p 的矩估计)

- $E(X) = mp \Rightarrow p = \frac{1}{m}E(X)$
- $E(\hat{X}) = \bar{X}$
- 矩估计: $\hat{p} = \frac{1}{m}\bar{X}$

例题 2.4 (拉普拉斯分布: 求 σ 的矩估计)

密度函数 $f(x) = \frac{1}{2\sigma} e^{-\frac{|x|}{\sigma}}$ 。

- $E(X) = \int_{-\infty}^{\infty} \frac{x}{2\sigma} e^{-\frac{|x|}{\sigma}} dx = 0$
- $E(X^2) = \int_{-\infty}^{\infty} \frac{x^2}{2\sigma} e^{-\frac{|x|}{\sigma}} dx = \frac{1}{\sigma} \int_0^{\infty} x^2 e^{-\frac{x}{\sigma}} dx$
- 积分计算过程:

$$- \int_0^{\infty} x^2 d(e^{-\frac{x}{\sigma}}) = \int_0^{\infty} 2xe^{-\frac{x}{\sigma}} dx = -2\sigma \int_0^{\infty} x d(e^{-\frac{x}{\sigma}}) = 2\sigma \int_0^{\infty} e^{-\frac{x}{\sigma}} dx = 2\sigma^2$$

- $\sigma = \sqrt{\frac{E(X^2)}{2}}$
- $E(\hat{X}^k) = \frac{1}{n} \sum_{i=1}^n X_i^k$
- 矩估计: $\hat{\sigma} = \sqrt{\frac{\sum_{i=1}^n X_i^2}{2n}}$

例题 2.5 (均匀分布 $U(a, b)$: 求 a 和 b 的矩估计)

- $E(X) = \frac{a+b}{2}$, $D(X) = \frac{1}{12}(b-a)^2$
- 参数与矩的关系:

$$\begin{cases} a = E(X) - \sqrt{3D(X)} \\ b = E(X) + \sqrt{3D(X)} \end{cases}$$
- 用样本矩估计总体矩: $E(\hat{X}) = \bar{X}$, $D(\hat{X}) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
- 矩估计 $\hat{a}$ 和 $\hat{b}$:

$$\hat{a} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

$$\hat{b} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$$

§ 2.3 极大似然估计法

极大似然思想

如果事件 A 发生了, 那么未知参数 θ 的值应该是在 Θ 中使事件 A 发生的概率 $P(A|\theta)$ 达到最大的那个值。

定义 2.6 (似然函数 $L(\theta)$)

- 设 $X_1, \dots, X_n$ 是总体 X 的 i.i.d. 样本, 密度 (或分布律) 为 $f(x; \theta)$
- 定义: $L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta)$ 称为似然函数
- 离散型: 似然函数为样本联合分布律 $\prod_{i=1}^n P_{\theta}\{x_i\}$
- 连续型: 似然函数为样本联合密度

定义 2.7 (极大似然估计 (MLE))

若有 $\hat{\theta} \in \Theta$ 使得 $\sup_{\theta \in \Theta} L(\theta) = L(\hat{\theta})$, 则称 $\hat{\theta}$ 为 θ 的极大似然估计, 记为 $\hat{\theta}_{MLE}$.

性质 2.8 (求 MLE 的步骤)

1. 做似然函数: $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
2. 做对数似然函数: $\ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta)$
3. 列似然方程: 令 $\frac{d}{d\theta} [\ln L(\theta)] = 0$
4. 若方程有解, 其解即为 $\hat{\theta}_{MLE}$

例题 2.9 (泊松分布 $P(\lambda)$: 求 λ 的 MLE)

- $L(\lambda) = \prod_{i=1}^n P\{X_i = x_i\} = \prod_{i=1}^n \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} = \frac{\lambda^{\sum_{i=1}^n x_i} e^{-n\lambda}}{\prod_{i=1}^n x_i!}$
- $\ln L(\lambda) = (\sum_{i=1}^n x_i) \ln \lambda - n\lambda - \sum_{i=1}^n \ln(x_i!)$
- 似然方程: $\frac{d}{d\lambda} [\ln L(\lambda)] = \frac{\sum_{i=1}^n x_i}{\lambda} - n = 0$
- **MLE:** $\hat{\lambda}_{MLE} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$

例题 2.10 (正态分布 $N(\mu, \sigma^2)$: 求 μ, σ^2 的 MLE)

- $\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$
- 似然方程组:

$$-\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0$$

$$-\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0$$
- **MLE:** $\hat{\mu}_{MLE} = \bar{X}, \hat{\sigma}_{MLE}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

注：若概率函数中含有多个未知参数，则可解方程组：

$$\frac{\partial \mathbf{L}}{\partial \theta_j} = 0 \quad \text{或} \quad \frac{\partial \ln \mathbf{L}}{\partial \theta_j} = 0 \quad (2.2)$$

定理 2.11 (MLE 的不变性)

若 $\hat{\theta}$ 是 θ 的 MLE, $u(\theta)$ 是 θ 的严格单调函数, 则 $u(\theta)$ 的 MLE 为 $u(\hat{\theta})$ 。

注：由似然方程解不出 θ 的似然估计时, 可由定义通过分析直接推求。事实上 $\hat{\theta}_{MLE}$ 满足

$$\mathbf{L}(\hat{\theta}_{MLE}) = \max_{\theta \in \Theta} \mathbf{L}(\theta) \quad (2.3)$$

例题 2.12 (指数分布 $E(\lambda)$: 求 $p = P\{X < a\}$ 的 MLE)

- $p = P\{X < a\} = 1 - e^{-\lambda a}$
- λ 的似然方程: $\frac{d}{d\lambda}[\ln L(\lambda)] = \frac{n}{\lambda} - \sum_{i=1}^n x_i = 0$
- $\hat{\lambda}_{MLE} = \frac{1}{\bar{X}}$
- **MLE:** $\hat{p}_{MLE} = 1 - e^{-\hat{\lambda}a} = 1 - e^{-\frac{a}{\bar{X}}}$

例题 2.13 (均匀分布 $U(0, \theta)$: 求 θ 的 MLE)

- $L(\theta) = \begin{cases} 1/\theta^n & 0 < x_i < \theta \text{ 对所有 } i \\ 0 & \text{其他} \end{cases}$
- 似然方程 $\frac{d}{d\theta}[\ln L(\theta)] = -\frac{n}{\theta} = 0$ 无解
- 通过分析 $L(\theta)$ 发现, 为使 $L(\theta) \neq 0$, 需 $\theta \in (\max(x_i), \infty)$ 。在此区间 $L(\theta) = 1/\theta^n$ 单调递减, 故当 θ 取最小值 $\max(x_i)$ 时, $L(\theta)$ 最大
- **MLE:** $\hat{\theta}_{MLE} = \max(X_i)$

§ 2.4 估计量的评选标准

2.4.1 无偏性

定义 2.14 (无偏性)

若 θ 的估计量 $\hat{\theta}$ 满足 $E(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ 是 θ 的无偏估计量。

例题 2.15 (均匀分布 $U(0, \theta)$)

$\hat{\theta}_M = 2\bar{X}$ 和 $\hat{\theta}_{MLE} = \max(X_i)$ 。

- $\hat{\theta}_M = 2\bar{X}$: $E(\hat{\theta}_M) = 2E(X) = 2 \cdot \frac{\theta}{2} = \theta$, 无偏
- $\hat{\theta}_{MLE} = \max(X_i)$: $E(\hat{\theta}_{MLE}) = \frac{n}{n+1}\theta \neq \theta$, 非无偏
- 无偏性修正: 取 $\theta^* = \frac{n+1}{n}\hat{\theta}_{MLE}$, 则 θ^* 是 θ 的无偏估计

2.4.2 有效性

定义 2.16 (有效性)

设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是 θ 的两个无偏估计量。若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$, 则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 更有效。

例题 2.17 (均匀分布 $U(0, \theta)$: 有效性比较)

比较 $\hat{\theta}_M = 2\bar{X}$ 和修正后的 $\hat{\theta}_{MLE}^* = \frac{n+1}{n}\hat{\theta}_{MLE}$ 。

- $D(\hat{\theta}_M) = \frac{\theta^2}{3n}$
- $D(\hat{\theta}_{MLE}^*) = \frac{\theta^2}{n(n+2)}$
- 比较方差比: $\frac{D(\hat{\theta}_M)}{D(\hat{\theta}_{MLE}^*)} = \frac{n+2}{3} \geq 1$
- 结论: 修正后的极大似然估计 $\hat{\theta}_{MLE}^*$ 更有效

2.4.3 一致性

定义 2.18 (一致性)

设 $\hat{\theta}_n$ 是 θ 的估计量。若 $\hat{\theta}_n \xrightarrow{P} \theta$ (依概率收敛于 θ)，则称 $\hat{\theta}_n$ 是 θ 的一致估计量。

例题 2.19 (二项分布 $B(m, p)$: 讨论 p 的 MLE $\hat{p}_{MLE}$ 的一致性)

- $\hat{p}_{MLE} = \frac{\bar{X}}{m}$
- 由辛钦大数定理, $\bar{X} \xrightarrow{P} E(X) = mp$
- $\hat{p}_{MLE} = \frac{\bar{X}}{m} \xrightarrow{P} \frac{mp}{m} = p$
- 结论: $\hat{p}_{MLE}$ 是一致估计量

2.4.4 附加例题 (最优无偏估计)

例题 2.20 (最优无偏估计)

$\bar{X}_1, \bar{X}_2$ 为来自总体 X 的两个样本均值, $a > 0, b > 0, a + b = 1$ 。证明 $\hat{\mu} = a\bar{X}_1 + b\bar{X}_2$ 是 $E(X)$ 的无偏估计, 并求使 $\hat{\mu}$ 最有效的 a, b 。

解.

- 无偏性: $E(a\bar{X}_1 + b\bar{X}_2) = aE(\bar{X}_1) + bE(\bar{X}_2) = (a + b)E(X) = E(X)$
- 有效性 (最小化方差): 设 $D(X) = \sigma^2$ 。

$$- D(\hat{\mu}) = a^2 D(\bar{X}_1) + b^2 D(\bar{X}_2) = \frac{a^2 \sigma^2}{n_1} + \frac{b^2 \sigma^2}{n_2}$$

$$- \text{令 } h(a) = \sigma^2 \left[\frac{a^2}{n_1} + \frac{(1-a)^2}{n_2} \right]$$

$$- \text{令 } \frac{d}{da} h(a) = 0, \text{ 解得 } a = \frac{n_1}{n_1 + n_2}$$

$$- \text{最有效的 } a, b: a = \frac{n_1}{n_1 + n_2}, b = \frac{n_2}{n_1 + n_2}$$

§ 2.5 区间估计

2.5.1 概念

定义 2.21 (置信区间)

设总体 X 的分布函数 $F(x; \theta)$ 含有未知参数 θ 。对于给定置信度 $1 - \alpha$ ($0 < \alpha < 1$)，若由样本确定的两个统计量 $\underline{\theta}, \bar{\theta}$ 使

$$P\{\underline{\theta} < \theta < \bar{\theta}\} = 1 - \alpha \quad (2.4)$$

则称随机区间 $(\underline{\theta}, \bar{\theta})$ 为 θ 的置信度为 $1 - \alpha$ 的置信区间。 $\underline{\theta}$ 和 $\bar{\theta}$ 分别称为置信下限和置信上限。

2.5.2 正态总体的抽样分布定理 (枢轴量)

性质 2.22 (正态总体的抽样分布 (枢轴量))

1. $\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$ (σ^2 已知)
2. $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$ ($\bar{X}$ 和 S^2 相互独立)
3. $T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$ (σ^2 未知)
4. 两个样本 ($\sigma_1^2 = \sigma_2^2 = \sigma^2$ 假定): $T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$, 其中 S_w 是混合样本方差的方根
5. 方差比: $F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$

2.5.3 正态总体参数的区间估计

表 2.1: 正态总体参数的区间估计

待估参数	条件	枢轴量 (Pivot Quantity)	置信区间	示例计算 (例 1)
μ	σ^2 已知	$U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\left(\bar{X} - U_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + U_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right)$	$n = 16, \bar{x} = 2.125, \sigma = 0.01, \alpha = 0.1, U_{0.05} = 1.645, (2.1209, 2.1291)$
μ	σ^2 未知	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$	$\left(\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right)$	$n = 16, \bar{x} = 2.125, s = 0.017, \alpha = 0.1, t_{0.05}(15) = 1.7531, (2.117, 2.132)$
σ^2	μ 未知	$\eta = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right)$	$n = 16, s^2 = 0.00029, \alpha = 0.05, \chi_{0.025}^2(15) = 27.488, \chi_{0.975}^2(15) = 6.262, \sigma \text{ 的区间: } (0.0127, 0.0265)$
$\mu_1 - \mu_2$	$\sigma_1^2 = \sigma_2^2$ 未知	$T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$	$(\bar{X} - \bar{Y}) \pm t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$	-
σ_1^2/σ_2^2	μ_1, μ_2 未知	$F = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$	$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right)$	-

假设检验

§ 3.1 假设检验的基本概念和思想

3.1.1 原假设与备择假设

定义 3.1 (原假设 (Null Hypothesis: H_0))

原假设是关于总体参数的一个没有效应、没有差异或没有关联的声明。

- **基本观点：**它代表了现状或没有变化的立场。在进行假设检验时，我们假设原假设是正确的，然后看样本数据是否提供了足够强的证据来推翻它。
- **符号：**通常包含等号 ($=, \geq, \leq$)。
- **例子：**
 - $\mu = 100$ ：总体平均值是 100。
 - $\mu_1 = \mu_2$ ：两组总体的平均值没有差异。
 - $\rho = 0$ ：两个变量之间没有相关性。

定义 3.2 (备择假设 (Alternative Hypothesis: H_A 或 H_1))

备择假设是研究者希望找到证据支持的声明，它与原假设对立。它通常声明存在效应、存在差异或存在关联。

- **基本观点：**如果我们有足够的统计证据来拒绝原假设，那么我们将接受备择假设。
- **形式：**备择假设决定了检验的方向性（单侧或双侧）：
 - **双侧检验 (Two-tailed)：**声明存在差异，但不指定方向。例子： $\mu \neq 100$ （平均值不等于 100）。
 - **单侧检验 (One-tailed: 右侧)：**声明大于某个值。例子： $\mu > 100$ （平均值大于 100）。
 - **单侧检验 (One-tailed: 左侧)：**声明小于某个值。例子： $\mu < 100$ （平均值小于 100）。

3.1.2 检验法则与拒绝域

定义 3.3 (检验法则与拒绝域)

样本观测值的全体组成样本空间 S ，把 S 分成两个互不相交的子集 W 和 W^* ，即

$$S = W \cup W^*, \quad W \cap W^* = \emptyset \quad (3.1)$$

假设当样本观测值 $(x^1, x^2, \dots, x^n) \in W$ 时，我们就拒绝 H_0 ；当样本观测值 $(x^1, x^2, \dots, x^n) \in W^*$ 时，我们就接受 H_0 。拒绝域或临界域即为 $W \subset S$ 。这种方法称为检验法则。

3.1.3 检验的两种错误

定义 3.4 (第一类错误 (弃真错误))

- **定义:** 当原假设 H_0 事实上是正确的, 但我们却根据样本数据拒绝了 H_0 。
- **概率:** 犯第一类错误的概率用 α 表示, 即**显著性水平** (Significance Level):

$$P(\text{Type I Error}) = P(\text{拒绝 } H_0 \mid H_0 \text{ 为真}) = \alpha \quad (3.2)$$

- **意义:** 错误地断定存在效应、差异或关联, 而实际上它们并不存在 (“错报” 或 “伪阳性”)。
- **控制:** α 是研究者在检验开始前预先设定的 (例如 $\alpha = 0.05$ 或 0.01), 因此**第一类错误的概率是直接可控的**。

定义 3.5 (第二类错误 (取伪错误))

- **定义:** 当原假设 H_0 事实上是错误的 (即备择假设 H_A 为真), 但我们却根据样本数据**不拒绝** H_0 。
- **概率:** 犯第二类错误的概率用 β 表示:

$$P(\text{Type II Error}) = P(\text{不拒绝 } H_0 \mid H_0 \text{ 为假}) = \beta \quad (3.3)$$

- **意义:** 错误地断定没有发现效应或差异, 而实际上它们是存在的 (“漏报” 或 “伪阴性”)。
- **控制:** β 的计算通常较为复杂, 且依赖于 H_A 成立的真实参数值。我们通常通过**统计功效** (Power) 来衡量减少第二类错误的程度。

3.1.4 显著性检验的基本步骤

性质 3.6 (显著性检验的基本步骤)

1. 根据实际问题作出假设 H_0 与 H_1 ;
2. 构造统计量, 在 H_0 真时其分布已知;
3. 给定显著性水平 α 的值, 参考 H_1 , 令

$$P(\text{拒绝 } H_0 \mid H_0 \text{ 为真}) = \alpha \quad (3.4)$$

求出拒绝域 W ;

4. 计算统计量的值, 若统计量 $\in W$, 则拒绝 H_0 , 否则接受 H_0 。

§ 3.2 单个正态总体的假设检验

3.2.1 单个正态总体均值的假设检验

定理 3.7 (σ^2 已知的情形: U 检验)

对于假设 $H_0: \mu = \mu_0$; $H_1: \mu \neq \mu_0$, 构造 U 统计量。 H_0 真时:

$$U = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (3.5)$$

由 $P\{|U| \geq U(\frac{\alpha}{2})\} = \alpha$, 可得拒绝域为 $|U| \geq U(\frac{\alpha}{2})$ 。

定理 3.8 (σ^2 未知的情形: t 检验)

$H_0: \mu = \mu_0$; $H_1: \mu \neq \mu_0$ 。 H_0 真时:

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (3.6)$$

由 $P\{|T| \geq t_{\alpha/2}(n-1)\} = \alpha$, 得水平为 α 的拒绝域为 $|T| \geq t_{\alpha/2}(n-1)$ 。

3.2.2 单个总体方差的假设检验

定理 3.9 (χ^2 检验法)

给定检验水平 α , 由观测值 $x_1, \dots, x_n$ 检验假设:

$$H_0: \sigma^2 = \sigma_0^2; \quad H_1: \sigma^2 \neq \sigma_0^2 \quad (3.7)$$

假设 μ 未知, 采用 χ^2 检验法。 H_0 下:

$$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1) \quad (3.8)$$

得水平为 α 的拒绝域为:

$$\chi^2 \leq \chi_{1-\alpha/2}^2(n-1) \quad \text{或} \quad \chi^2 \geq \chi_{\alpha/2}^2(n-1) \quad (3.9)$$

§3.3 双正态总体均值与方差比的假设检验

设 $X_1, \dots, X_{n_1} \sim N(\mu_1, \sigma_1^2); \quad Y_1, \dots, Y_{n_2} \sim N(\mu_2, \sigma_2^2)$, 两样本独立, 给定检验水平 α , 由观测值 $x_1, \dots, x_{n_1}; \quad y_1, \dots, y_{n_2}$ 检验假设。

3.3.1 均值差的假设检验

定理 3.10 (均值差的假设检验: t 检验法)

检验假设 $H_0: \mu_1 = \mu_2; \quad H_1: \mu_1 \neq \mu_2$ 。假定 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 。 H_0 下:

$$T = \frac{\bar{X} - \bar{Y}}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2) \quad (3.10)$$

其中 S_w 是联合样本方差的平方根。由 $P\{|T| \geq t_{\alpha/2}(n_1 + n_2 - 2)\} = \alpha$, 即得拒绝域 $|T| \geq t_{\alpha/2}(n_1 + n_2 - 2)$ 。

3.3.2 方差比的假设检验

定理 3.11 (方差比的假设检验: F 检验法)

检验假设 $H_0: \sigma_1^2 = \sigma_2^2$; $H_1: \sigma_1^2 \neq \sigma_2^2$ 。假定 μ_1, μ_2 未知。 H_0 真时:

$$F = \frac{S_1^2}{S_2^2} \sim F(n_1 - 1, n_2 - 1) \quad (3.11)$$

由

$$P\{F \leq F_{1-\alpha/2}(n_1 - 1, n_2 - 1) \text{ 或 } F \geq F_{\alpha/2}(n_1 - 1, n_2 - 1)\} = \alpha \quad (3.12)$$

得拒绝域:

$$F \leq F_{1-\alpha/2}(n_1 - 1, n_2 - 1) \text{ 或 } F \geq F_{\alpha/2}(n_1 - 1, n_2 - 1) \quad (3.13)$$