

概率论笔记

魏舟

2026 年 7 月 27 日

目录

第 1 章	概率论的基础知识	1
1.1	随机试验与样本空间	1
1.2	事件间的关系与运算	2
1.2.1	基本关系	2
1.2.2	事件的运算律	2
1.3	概率的定义与性质	3
1.3.1	Kolmogorov 公理化定义	3
1.3.2	概率的基本性质	3
1.4	古典概型	4
1.5	条件概率与独立性	4
1.6	全概率公式与贝叶斯公式	5
第 2 章	随机变量及其分布	7
2.1	随机变量的概念	7
2.2	离散型随机变量的分布律	8
2.2.1	常见的离散型分布	8
2.3	随机变量的分布函数	10
2.4	连续型随机变量及其概率密度	11
2.4.1	常见的连续型分布	12
2.5	随机变量函数的分布	15
第 3 章	多维随机变量及其分布	17
3.1	二维随机变量的分布	17
3.2	二维离散型随机变量	18
3.3	二维连续型随机变量	18
3.3.1	两个常用的二维连续型分布	19
3.4	边缘分布	20
3.4.1	边缘分布函数	20
3.4.2	离散型：边缘分布律	20
3.4.3	连续型：边缘密度函数	21
3.5	随机变量的独立性	21
3.6	两个随机变量函数的分布	21
3.6.1	离散型情形	21

3.6.2	连续型情形	22
3.6.3	常见函数的密度公式	23
第 4 章	随机变量的数字特征	25
4.1	数学期望（均值）	25
4.1.1	常见分布的期望	26
4.2	方差	26
4.2.1	常见分布的方差	27
4.3	Chebyshev 不等式	27
4.4	协方差与相关系数	28
4.5	协方差矩阵	29
4.6	独立与不相关的关系	29
第 5 章	大数定律与中心极限定理	31
5.1	依概率收敛	31
5.2	大数定律（LLN）	31
5.3	中心极限定理（CLT）	32
5.4	中心极限定理的应用	33
5.5	大数定律与中心极限定理的比较	34
附录：	补充知识	35
.6	Γ 函数（Gamma Function）	35
.7	常用积分公式	35
.8	正态分布的矩	36
.9	重要分布的可加性	36
.10	常用分布的期望与方差总表	37
.11	独立与不相关的区别	37

概率论的基础知识

概率论是研究随机现象数量规律的数学分支，也是数理统计、随机过程等学科的理论基础。

§ 1.1

随机试验与样本空间

随机试验

对随机现象的观察，称为**随机试验**（简称试验），记为 E 。

随机试验具有以下三个特点：

1. 可在相同条件下重复进行；
2. 试验结果可能不止一个，但能明确所有的可能结果；
3. 试验前无法确定是哪个结果会出现。

样本空间与样本点

试验的所有可能结果所组成的集合，称为**样本空间**，记为

$$\Omega = \{\omega\}.$$

其中每个元素 ω 称为**样本点**。

随机事件

试验中可能出现也可能不出现的情况称为**随机事件**，记作 A, B, C 等。任何事件均对应着样本空间的某个子集。

特殊事件：

- **必然事件**：样本空间 Ω ；
- **不可能事件**：空集 $\emptyset$ ；

- 基本事件：只包含一个样本点的事件 $\{\omega\}$ 。

【例题 1.1】(掷骰子) 掷一颗骰子，考察可能出现的点数。

- 样本空间： $S_4 = \{1, 2, 3, 4, 5, 6\}$ ；
- 事件 $A = \text{“掷出偶数点”} = \{2, 4, 6\}$ ；
- 事件 $B = \text{“掷出大于 4 的点”} = \{5, 6\}$ 。

§1.2 事件间的关系与运算

1.2.1 基本关系

1. 包含关系： $A \subset B$ (A 发生必导致 B 发生)；
2. 和事件： $A \cup B$, A 与 B 至少有一个发生；
3. 积事件： $AB = A \cap B$, A 与 B 同时发生；
4. 差事件： $A - B$, A 发生而 B 不发生；
5. 互斥事件： $AB = \emptyset$ ；
6. 互逆事件： $A \cup B = \Omega$ 且 $AB = \emptyset$, 此事 A 与 B 互为逆事件，记为 $B = \bar{A}$ 。

1.2.2 事件的运算律

事件运算法则

1. 交换律： $A \cup B = B \cup A$, $AB = BA$ ；
2. 结合律： $(A \cup B) \cup C = A \cup (B \cup C)$, $(AB)C = A(BC)$ ；
3. 分配律： $(A \cup B)C = (AC) \cup (BC)$, $(AB) \cup C = (A \cup C)(B \cup C)$ ；
4. 对偶律 (De Morgan 定律)：

$$\overline{A \cup B} = \bar{A} \cap \bar{B}, \quad \overline{AB} = \bar{A} \cup \bar{B}$$

可推广为：

$$\overline{\bigcup_k A_k} = \bigcap_k \bar{A}_k, \quad \overline{\bigcap_k A_k} = \bigcup_k \bar{A}_k$$

§ 1.3 概率的定义与性质

1.3.1 Kolmogorov 公理化定义

设 Ω 为样本空间, $\mathcal{F}$ 为事件域 (σ -代数), 概率 P 是定义在 $\mathcal{F}$ 上的实值函数, 满足:

概率公理 (Kolmogorov 1933)

1. 非负性: $\forall A \in \mathcal{F}, P(A) \geq 0$;
2. 规范性: $P(\Omega) = 1$;
3. 可列可加性: 若 $A_1, A_2, \dots$ 两两互不相容, 则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i).$$

1.3.2 概率的基本性质

概率性质

1. $P(\emptyset) = 0$;
2. 有限可加性: 若 $A_1, \dots, A_n$ 两两互不相容, 则

$$P(A_1 \cup A_2 \cup \dots \cup A_n) = \sum_{i=1}^n P(A_i);$$

3. 事件差公式: $P(A - B) = P(A) - P(AB)$;
4. 加法公式: 对任意两事件 A, B , 有

$$P(A \cup B) = P(A) + P(B) - P(AB);$$

推广到三个事件:

$$\begin{aligned} P(A \cup B \cup C) &= P(A) + P(B) + P(C) \\ &\quad - P(AB) - P(AC) - P(BC) + P(ABC); \end{aligned}$$

5. 互补性: $P(\overline{A}) = 1 - P(A)$ 。

§1.4 古典概型

若样本空间 Ω 只包含有限个样本点，且每个样本点出现的可能性相等，则称为**古典概型**。事件 A 的概率为：

$$P(A) = \frac{|A|}{|\Omega|} = \frac{A \text{ 包含的样本点数}}{\text{样本点总数}}$$

【例题 1.2】(古典概型抽球公式) 盒中有 N 个球，其中 M 个白球。现从中任抽 n 个球，则这 n 个球中恰有 k 个白球的概率为：

$$P = \frac{C_M^k \cdot C_{N-M}^{n-k}}{C_N^n}.$$

§1.5 条件概率与独立性

条件概率

设 A, B 为两个事件，且 $P(A) > 0$ ，则称

$$P(B | A) = \frac{P(AB)}{P(A)}$$

为在事件 A 发生的条件下事件 B 发生的条件概率。

【定理 1.3】(乘法公式与链式法则) 由条件概率定义直接可得：

$$P(AB) = P(A) \cdot P(B | A).$$

一般形式 (链式法则)：

$$P(A_1 A_2 \cdots A_n) = P(A_1) P(A_2 | A_1) P(A_3 | A_1 A_2) \cdots P(A_n | A_1 \cdots A_{n-1}).$$

事件的独立性

若 $P(AB) = P(A)P(B)$ ，则称事件 A 与 B 相互独立，记为 $A \perp B$ 。

多个事件的独立性

设 $A_1, A_2, \dots, A_n$ 为 n 个事件。若对任意 k ($2 \leq k \leq n$) 和任意 $1 \leq i_1 < i_2 < \dots < i_k \leq n$, 有

$$P(A_{i_1} A_{i_2} \cdots A_{i_k}) = P(A_{i_1}) P(A_{i_2}) \cdots P(A_{i_k}),$$

则称 $A_1, A_2, \dots, A_n$ 相互独立。

注. 两两独立不等价于相互独立。相互独立要求任意子集的乘积概率等于各自概率的乘积。

【例题 1.4】(独立性证明) 证明：若 A, B 相互独立，则 A 与 $\bar{B}$ 相互独立。

解.

$$\begin{aligned} P(A\bar{B}) &= P(A - AB) = P(A) - P(AB) \quad (\text{事件差公式}) \\ &= P(A) - P(A)P(B) \quad (\text{因 } A, B \text{ 独立}) \\ &= P(A)[1 - P(B)] = P(A)P(\bar{B}). \end{aligned}$$

故 A 与 $\bar{B}$ 相互独立。

§ 1.6 全概率公式与贝叶斯公式

【定理 1.5】(全概率公式) 设 $A_1, A_2, \dots, A_n$ 为样本空间 Ω 的一个完备事件组 (即两两互斥且 $\bigcup_{i=1}^n A_i = \Omega$)，且 $P(A_i) > 0$ ，则对任意事件 B ，有

$$P(B) = \sum_{i=1}^n P(A_i)P(B | A_i).$$

【定理 1.6】(贝叶斯公式) 在全概率公式的相同条件下，有

$$P(A_j | B) = \frac{P(A_j)P(B | A_j)}{\sum_{i=1}^n P(A_i)P(B | A_i)}, \quad j = 1, 2, \dots, n.$$

贝叶斯公式的理解

- $P(A_j)$ 称为先验概率 (prior)，是试验前对 A_j 的认知；
- $P(B | A_j)$ 称为似然 (likelihood)，是新数据带来的信息；
- $P(A_j | B)$ 称为后验概率 (posterior)，是在观察到 B 发生之后对 A_j 的更新判断。

贝叶斯公式本质上是一种“用新数据更新旧信念”的数学机制。

【例题 1.7】(袋子抽球——全概率公式) 甲袋 (2 白, 1 红), 乙袋 (2 红, 1 白)。从甲袋中任取一球放入乙袋, 再从乙袋任取一球是红球 (B) 的概率。

设 A_1 ——从甲袋放入乙袋的是白球, $P(A_1) = 2/3$; A_2 ——从甲袋放入乙袋的是红球, $P(A_2) = 1/3$ 。

- 若 A_1 发生 (乙袋变为 2 白 2 红): $P(B | A_1) = 2/4 = 1/2$;
- 若 A_2 发生 (乙袋变为 1 白 3 红): $P(B | A_2) = 3/4$ 。

由全概率公式:

$$P(B) = P(B | A_1)P(A_1) + P(B | A_2)P(A_2) = \frac{1}{2} \cdot \frac{2}{3} + \frac{3}{4} \cdot \frac{1}{3} = \frac{7}{12}.$$

注. [概率为 0 的事件] 概率为 0 的事件不一定是不可能事件。例如在连续型随机变量中, 取任意指定值的概率均为 0, 但该事件仍可能发生。

随机变量及其分布

引入随机变量的概念，将样本空间中的结果映射到实数集，使概率论可以与微积分等分析工具结合。

§2.1 随机变量的概念

随机变量

设 $S = \{e\}$ 是试验的样本空间，如果量 X 是定义在 S 上的一个单值实值函数，即

$$X : S \rightarrow \mathbb{R},$$

则称 X 为随机变量 (r.v.)。

随机变量的引入意义在于将随机试验的结果数量化，从而可以用数学分析的方法来研究随机现象。

分类：

- 离散型随机变量：取值有限或可列无穷多个；
- 连续型随机变量：取值充满某个区间，分布函数可表为密度函数的积分；
- 奇异型/混合型：非以上二者。

§2.2 离散型随机变量的分布律

分布律（概率质量函数，PMF）

若 X 取值 $x_1, x_2, \dots, x_k, \dots$ 且取这些值的概率依次为 $p_1, p_2, \dots, p_k, \dots$ ，则称

$$P\{X = x_k\} = p_k \quad (k = 1, 2, \dots)$$

为 X 的分布律。

分布律的基本性质

1. 非负性： $p_k \geq 0$;
2. 归一性： $\sum_k p_k = 1$ 。

2.2.1 常见的离散型分布

两点分布（0-1 分布）


记作 $X \sim B(1, p)$ 。用于描述一次 Bernoulli 试验（只有成功和失败两种结果）。

X	1	0
p_k	p	$1 - p$

二项分布

记作 $X \sim B(n, p)$ 。 X 表示 n 重 Bernoulli 试验中事件 A 发生的次数， $p = P(A)$ 。

$$P\{X = k\} = C_n^k p^k (1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n.$$

图 2.1: 二项分布 $B(20, p)$ 在不同 p 下的分布律**Poisson 分布 $X \sim P(\lambda)$**

参数 $\lambda > 0$ 表示单位时间内随机事件的平均发生次数。

$$P\{X = k\} = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$$

【定理 2.1】(Poisson 逼近定理) 当 n 很大而 p 很小时，二项分布 $B(n, p)$ 可用 Poisson 分布 $P(np)$ 近似：


$$C_n^k p^k (1-p)^{n-k} \approx \frac{(np)^k}{k!} e^{-np}.$$

一般当 $n \geq 20$, $p \leq 0.05$ 时，近似效果较好。

【例题 2.2】(Poisson 分布计算) 已知 $X \sim P(\lambda)$ ，且 $P\{X = 0\} = e^{-6}$ ，求 $P\{X \geq 2\}$ 。

解. 由 $P\{X = 0\} = \frac{\lambda^0}{0!} e^{-\lambda} = e^{-\lambda} = e^{-6}$ 得 $\lambda = 6$ 。

$$\begin{aligned} P\{X \geq 2\} &= 1 - P\{X < 2\} \\ &= 1 - [P\{X = 0\} + P\{X = 1\}] \\ &= 1 - (e^{-6} + 6e^{-6}) = 1 - 7e^{-6} \approx 0.9826. \end{aligned}$$

图 2.2: Poisson 分布 $P(\lambda)$ 在不同参数 λ 下的分布律

§2.3 随机变量的分布函数

分布函数（累积分布函数，CDF）

设 X 是一个随机变量，分布函数 $F(x)$ 定义为：

$$F(x) = P\{X \leq x\}, \quad -\infty < x < +\infty.$$

由此可得： $P\{a < X \leq b\} = F(b) - F(a)$.

分布函数的性质

1. 单调不减性：若 $x_1 < x_2$ ，则 $F(x_1) \leq F(x_2)$ ；

2. 有界性： $0 \leq F(x) \leq 1$ ，且

$$\lim_{x \rightarrow -\infty} F(x) = 0, \quad \lim_{x \rightarrow +\infty} F(x) = 1;$$

3. 右连续性： $\lim_{x \rightarrow x_0^+} F(x) = F(x_0)$ ；

4. 利用分布函数计算概率：

$$P\{a < X \leq b\} = F(b) - F(a)$$

$$P\{X > a\} = 1 - F(a)$$

$$P\{X = a\} = F(a) - F(a-0)$$

$$P\{X < a\} = F(a-0)$$

§2.4 连续型随机变量及其概率密度

概率密度函数 (PDF)

若存在非负函数 $f(x)$ ，使得 X 的分布函数 $F(x)$ 可表示为

$$F(x) = \int_{-\infty}^x f(t) dt,$$

则称 $f(x)$ 为 X 的概率密度函数，称 X 为连续型随机变量。

概率密度函数的性质

1. 非负性： $f(x) \geq 0$ ；

2. 归一性： $\int_{-\infty}^{+\infty} f(x) dx = 1$ ；

3. 概率计算： $P\{a < X < b\} = \int_a^b f(x) dx = F(b) - F(a)$ ；

4. 在 $f(x)$ 的连续点处： $F'(x) = f(x)$ 。

2.4.1 常见的连续型分布

均匀分布

记作 $X \sim U(a, b)$ 。

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其他.} \end{cases} \quad F(x) = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x < b, \\ 1, & x \geq b. \end{cases}$$





图 2.3: 均匀分布 $U(a, b)$ 的概率密度函数

指数分布 $X \sim E(\lambda)$, $\lambda > 0$

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases} \quad F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

图 2.4: 指数分布 $E(\lambda)$ 在不同参数 λ 下的概率密度函数

指数分布的无记忆性

对任意 $s, t > 0$, 有

$$P(X > s + t \mid X > s) = P(X > t).$$

在连续型分布中, 只有指数分布具有无记忆性。这意味着一个已经等待了 s 时间的事件, 继续等待 t 时间的概率与从零开始等待 t 时间的概率相同。

证明:

$$\begin{aligned} P(X > s + t \mid X > s) &= \frac{P(X > s + t, X > s)}{P(X > s)} = \frac{P(X > s + t)}{P(X > s)} \\ &= \frac{1 - F(s + t)}{1 - F(s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t} = P(X > t). \end{aligned}$$

正态 (Gaussian) 分布

记作 $X \sim N(\mu, \sigma^2)$ 。

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad -\infty < x < +\infty.$$

标准正态分布 $Z \sim N(0, 1)$:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}, \quad \Phi(x) = \int_{-\infty}^x \varphi(t) dt.$$

一般正态分布的标准化:

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1).$$

3σ 原则

对于 $X \sim N(\mu, \sigma^2)$:

$$P\{|X - \mu| < \sigma\} \approx 0.6827,$$

$$P\{|X - \mu| < 2\sigma\} \approx 0.9545,$$

$$P\{|X - \mu| < 3\sigma\} \approx 0.9973.$$

即正态随机变量取值几乎都落在均值 $\pm 3\sigma$ 的范围内。




图 2.5: 正态分布 $N(\mu, \sigma^2)$ 的概率密度函数

【例题 2.3】(求参数、概率与分布函数) 已知 X 的概率密度函数为

$$f(x) = \begin{cases} Ax^2, & 0 < x < 1, \\ 0, & \text{其他.} \end{cases}$$

解. (1) 求参数 A : 由归一性:

$$\int_0^1 Ax^2 dx = A \cdot \frac{x^3}{3} \Big|_0^1 = \frac{A}{3} = 1 \Rightarrow A = 3.$$

(2) 求 $P\{0.5 < X < 3\}$:

$$P\{0.5 < X < 3\} = \int_{0.5}^1 3x^2 dx = x^3 \Big|_{0.5}^1 = 1 - 0.125 = 0.875.$$

(3) 求分布函数 $F(x)$:

$$F(x) = \begin{cases} 0, & x \leq 0, \\ \int_0^x 3t^2 dt = x^3, & 0 < x < 1, \\ 1, & x \geq 1. \end{cases}$$

§2.5 随机变量函数的分布

【定理 2.4】(公式法 (单调变换)) 设 $X \sim f_X(x)$, $Y = g(X)$ 是严格单调可导函数, g^{-1} 为其反函数。则 Y 的概率密度函数为:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{d}{dy} g^{-1}(y) \right|.$$

【例题 2.5】(线性变换) 已知 $X \sim N(\mu, \sigma^2)$, 求 $Y = \frac{X - \mu}{\sigma}$ 的概率密度。

解. 反函数 $x = g^{-1}(y) = \sigma y + \mu$, 导数为 σ 。故

$$f_Y(y) = f_X(\sigma y + \mu) \cdot \sigma = \frac{1}{\sqrt{2\pi}} e^{-y^2/2},$$

即 $Y \sim N(0, 1)$ 。

注. [非单调变换的处理] 若 g 非单调, 可先求分布函数再求导:

$$F_Y(y) = P\{g(X) \leq y\} = \int_{\{x: g(x) \leq y\}} f_X(x) dx,$$

然后 $f_Y(y) = F'_Y(y)$ 。

多维随机变量及其分布

实际问题中往往需要同时考虑多个随机变量，多维随机变量的研究是概率论从一元到多元的自然推广。

§3.1
二维随机变量的分布

联合分布函数

设 (X, Y) 为二维随机变量，联合分布函数 $F(x, y)$ 定义为：

$$F(x, y) = P\{X \leq x, Y \leq y\}.$$

矩形区域概率

对于 $x_1 < x_2, y_1 < y_2$,

$$P\{x_1 < X \leq x_2, y_1 < Y \leq y_2\} = F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1).$$

联合分布函数的性质

1. 归一性：

$$F(+\infty, +\infty) = 1, \quad F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0;$$

2. 对每个变量单调不减；

3. 对每个变量右连续；

4. 矩形不等式（非负性）：对 $x_1 < x_2, y_1 < y_2$,

$$F(x_2, y_2) - F(x_1, y_2) - F(x_2, y_1) + F(x_1, y_1) \geq 0.$$

§3.2 二维离散型随机变量

联合分布律

若 (X, Y) 所有可能取值为有限对或可列无限多对, 则称其为二维离散型随机变量。其联合分布律为:

$$P\{X = x_i, Y = y_j\} = p_{ij} \quad (i, j = 1, 2, \dots).$$

满足 $p_{ij} \geq 0$ 且 $\sum_i \sum_j p_{ij} = 1$ 。

通常用分布表格表示:

$X \setminus Y$	y_1	y_2	$\cdots$	y_j
x_1	p_{11}	p_{12}	$\cdots$	p_{1j}
x_2	p_{21}	p_{22}	$\cdots$	p_{2j}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$

§3.3 二维连续型随机变量

联合概率密度函数

若存在非负函数 $f(x, y)$, 使得

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv,$$

则称 $f(x, y)$ 为 (X, Y) 的联合概率密度函数。

联合密度函数的性质

1. 归一性: $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1;$

2. 密度函数与分布函数的关系:

$$f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y};$$

3. 对任意平面区域 $G \subset \mathbb{R}^2$,

$$P\{(X, Y) \in G\} = \iint_G f(x, y) dx dy.$$

3.3.1 两个常用的二维连续型分布

二维均匀分布

设 $D \subset \mathbb{R}^2$ 为有界区域, 面积为 S_D 。若

$$f(x, y) = \begin{cases} \frac{1}{S_D}, & (x, y) \in D, \\ 0, & (x, y) \notin D, \end{cases}$$

则称 (X, Y) 在 D 上服从均匀分布。

二维正态分布

记作 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right)\right].$$

其中:

- μ_1, μ_2 : 分别是 X 和 Y 的数学期望, 决定分布中心的位置;
- σ_1, σ_2 : 分别是 X 和 Y 的标准差, 决定轴向“胖瘦”;
- ρ : 相关系数, 反映 X 和 Y 之间的线性相关程度 ($-1 \leq \rho \leq 1$)。

二维正态分布的重要性质

1. 边缘分布依然是正态的: $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ 。但反之不一定成立 (即边缘分布为正态, 联合分布未必是正态);
2. 线性变换不变性: $aX + bY \sim N(a\mu_1 + b\mu_2, a^2\sigma_1^2 + b^2\sigma_2^2 + 2ab\rho\sigma_1\sigma_2)$;
3. 独立性与相关性的等价性: 对于二维正态分布, 独立与不相关 ($\rho = 0$) 是互为充要条件的;
4. 等高线是椭圆: 密度相等的点轨迹是一个椭圆, 椭圆的方向和倾斜度由 ρ 和 σ 决定。




图 3.1: 二维正态分布的联合概率密度曲面与等高线

§3.4 边缘分布

3.4.1 边缘分布函数

从联合分布函数 $F(x, y)$ 中令另一个变量趋于无穷大, 即得边缘分布函数:

$$F_X(x) = F(x, +\infty) = \lim_{y \rightarrow +\infty} F(x, y),$$

$$F_Y(y) = F(+\infty, y) = \lim_{x \rightarrow +\infty} F(x, y).$$

3.4.2 离散型: 边缘分布律

$$P\{X = x_i\} = \sum_j p_{ij} \quad (\text{行和}),$$

$$P\{Y = y_j\} = \sum_i p_{ij} \quad (\text{列和}).$$

3.4.3 连续型：边缘密度函数

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy,$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$$

几何理解：对 y 积分相当于将三维曲面沿 y 方向“压扁”投影到 x 轴上；对 x 积分则投影到 y 轴上。

§3.5
随机变量的独立性

独立性

X 与 Y 相互独立，当且仅当联合分布函数等于边缘分布函数的乘积：

$$F(x, y) = F_X(x) \cdot F_Y(y).$$

判定条件：

- 连续型： $X \perp\!\!\!\perp Y \iff f(x, y) = f_X(x)f_Y(y)$ 几乎处处成立；
- 离散型： $X \perp\!\!\!\perp Y \iff p_{ij} = p_{i\cdot} \cdot p_{\cdot j}$ 对所有 i, j 成立。

【定理 3.1】(二维正态分布的独立性) 设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，则

$$X \perp\!\!\!\perp Y \iff \rho = 0.$$

§3.6
两个随机变量函数的分布

3.6.1 离散型情形

设 $Z = g(X, Y)$ ，其分布律为：

$$P\{Z = z_k\} = \sum_{g(x_i, y_j) = z_k} P\{X = x_i, Y = y_j\}.$$

和的分布

$Z = X + Y$ 。

$$P\{Z = z\} = \sum_i P\{X = x_i, Y = z - x_i\}.$$

若 $X \perp\!\!\!\perp Y$ ，则为离散卷积：

$$P\{Z = z\} = \sum_i P\{X = x_i\} \cdot P\{Y = z - x_i\}.$$

最值分布

设 $X_1, \dots, X_n$ 相互独立，分布函数分别为 $F_1, \dots, F_n$ ，则

$$\begin{aligned} F_M(z) &= F_1(z)F_2(z) \cdots F_n(z), \\ F_N(z) &= 1 - [1 - F_1(z)][1 - F_2(z)] \cdots [1 - F_n(z)]. \end{aligned}$$

其中 $M = \max\{X_1, \dots, X_n\}$ ， $N = \min\{X_1, \dots, X_n\}$ 。

3.6.2 连续型情形**分布函数法（通用方法）**

设 $Z = g(X, Y)$ ：

1. 先求 CDF: $F_Z(z) = P\{g(X, Y) \leq z\} = \iint_{g(x, y) \leq z} f(x, y) dx dy$;
2. 求导得 PDF: $f_Z(z) = \frac{d}{dz} F_Z(z)$ 。

关键在于确定积分区域 $D_z = \{(x, y) \mid g(x, y) \leq z\}$ 。

变量代换法 (Jacobi 行列式法)

设变换 $u = g_1(x, y)$, $v = g_2(x, y)$, 逆变换 $x = h_1(u, v)$, $y = h_2(u, v)$, 则

$$f_{U,V}(u, v) = f_{X,Y}(h_1(u, v), h_2(u, v)) \cdot |J|,$$

其中 Jacobi 行列式:

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix}.$$

最后通常需要对 v 求边缘分布来得到 U 的密度: $f_U(u) = \int_{-\infty}^{+\infty} f_{U,V}(u, v) dv$ 。

3.6.3 常见函数的密度公式

和的分布 (卷积公式)

$Z = X + Y$, $X \perp\!\!\!\perp Y$ 。

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(z - x) dx.$$

商的分布

$Z = Y/X$, $X \perp\!\!\!\perp Y$, $X > 0$ 。

$$f_Z(z) = \int_0^{+\infty} x f_X(x) f_Y(zx) dx.$$

正态分布的可加性

若 $X \sim N(\mu_1, \sigma_1^2)$, $Y \sim N(\mu_2, \sigma_2^2)$ 且独立, 则

$$X \pm Y \sim N(\mu_1 \pm \mu_2, \sigma_1^2 + \sigma_2^2).$$

更一般地, 独立正态随机变量的线性组合仍服从正态分布。

随机变量的数字特征

分布函数完整地描述了随机变量的统计规律，但在实际应用中，往往只需要少数几个数字特征就能把握其主要性质。

§4.1 数学期望（均值）

离散型随机变量的期望

设离散型随机变量 X 的分布律为 $P\{X = x_k\} = p_k$ ，若级数 $\sum_k |x_k| p_k$ 收敛，则定义

$$E(X) = \sum_{k=1}^{\infty} x_k p_k$$

为 X 的数学期望。

连续型随机变量的期望

设连续型随机变量 X 的概率密度函数为 $f(x)$ ，若 $\int_{-\infty}^{+\infty} |x| f(x) dx$ 收敛，则定义

$$E(X) = \int_{-\infty}^{+\infty} x f(x) dx$$

为 X 的数学期望。

注. 随机变量期望存在的条件是绝对收敛： $\sum |x_k| p_k < \infty$ （离散型）或 $\int |x| f(x) dx < \infty$ （连续型）。这是为了确保期望值不依赖于求和或积分的次序。Cauchy 分布就是期望不存在的典型例子。

【定理 4.1】（随机变量函数的期望（LOTUS 定理）） • 一维离散型： $E[g(X)] = \sum_k g(x_k) p_k$ ；

• 一维连续型： $E[g(X)] = \int_{-\infty}^{+\infty} g(x) f(x) dx$ ；

• 二维连续型： $E[g(X, Y)] = \iint_{\mathbb{R}^2} g(x, y) f(x, y) dx dy$ 。

该定理的实用价值在于：求 $g(X)$ 的期望时，不需要先求出 $Y = g(X)$ 的分布，直接利用 X 的分布即可。

期望的基本性质

1. $E(C) = C$ (常数的期望等于本身);
2. 线性性: $E(aX + bY + c) = aE(X) + bE(Y) + c$ (不要求独立!);
3. 若 $X \perp\!\!\!\perp Y$, 则 $E(XY) = E(X)E(Y)$ (逆命题不成立);
4. 单调性: 若 $X \leq Y$ a.s., 则 $E(X) \leq E(Y)$;
5. $|E(X)| \leq E(|X|)$ 。

4.1.1 常见分布的期望

分布	符号	期望 $E(X)$
两点分布	$B(1, p)$	p
二项分布	$B(n, p)$	np
Poisson 分布	$P(\lambda)$	λ
均匀分布	$U(a, b)$	$\frac{a+b}{2}$
指数分布	$E(\lambda)$	$\frac{1}{\lambda}$
正态分布	$N(\mu, \sigma^2)$	μ

§4.2 方差

方差与标准差

设 X 为随机变量，其方差定义为：

$$D(X) = \text{Var}(X) = E[(X - E(X))^2].$$

标准差: $\sigma(X) = \sqrt{D(X)}$ 。方差刻画了随机变量取值相对于均值的离散程度。

【定理 4.2】(方差的计算公式)

$$D(X) = E(X^2) - [E(X)]^2.$$

此公式通常比定义式更便于计算。

方差的性质

1. $D(C) = 0$; 若 $D(X) = 0$, 则 $P\{X = C\} = 1$ (退化的随机变量);
2. $D(aX + b) = a^2 D(X)$ (方差不满足线性性!);
3. 若 $X \perp\!\!\!\perp Y$, 则 $D(X + Y) = D(X) + D(Y)$;
4. 一般情形: $D(X \pm Y) = D(X) + D(Y) \pm 2\text{Cov}(X, Y)$ 。

4.2.1 常见分布的方差

分布	符号	方差 $D(X)$
两点分布	$B(1, p)$	$p(1 - p)$
二项分布	$B(n, p)$	$np(1 - p)$
Poisson 分布	$P(\lambda)$	λ
均匀分布	$U(a, b)$	$\frac{(b - a)^2}{12}$
指数分布	$E(\lambda)$	$\frac{1}{\lambda^2}$
正态分布	$N(\mu, \sigma^2)$	σ^2

注. [Poisson 分布的期望与方差相等] λ 既是 Poisson 分布的期望, 也是方差, 这是一个重要的特征性质。在统计分析中, 若样本均值与样本方差接近, 则数据可能服从 Poisson 分布。

§ 4.3

Chebyshev 不等式

【定理 4.3】(Chebyshev 不等式) 设随机变量 X 具有数学期望 $E(X) = \mu$ 和方差 $D(X) = \sigma^2$ 。则对任意 $\varepsilon > 0$, 有

$$P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}.$$

等价形式 (令 $\varepsilon = k\sigma$):

$$P\{|X - \mu| \geq k\sigma\} \leq \frac{1}{k^2}.$$

该不等式的威力在于: 无论随机变量服从什么分布 (只要方差存在), 它都成立。它给出了随机变量偏离期望的概率上界。

- 取 $k = 2$: 偏离 2σ 以上的概率不超过 $1/4 = 25\%$;
- 取 $k = 3$: 偏离 3σ 以上的概率不超过 $1/9 \approx 11.1\%$ 。

注. 对于正态分布, $P(|X - \mu| \geq 3\sigma) \approx 0.27\%$, 远小于 Chebyshev 不等式给出的 11% 。这说明 Chebyshev 不等式是保守的界限, 但它的普适性使得它在理论证明中非常有用。

§4.4 协方差与相关系数

协方差

随机变量 X 与 Y 的协方差定义为:

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))].$$

计算公式:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y).$$

不相关

若 $\text{Cov}(X, Y) = 0$, 则称 X 与 Y 不相关。

协方差的性质

1. $\text{Cov}(X, X) = D(X)$;
2. $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (对称性);
3. $\text{Cov}(aX, bY) = ab \cdot \text{Cov}(X, Y)$;
4. $\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$ (双线性性);
5. 若 $X \perp Y$, 则 $\text{Cov}(X, Y) = 0$ (逆命题不成立, 正态分布除外)。

相关系数

X 与 Y 的相关系数 (Pearson correlation coefficient) 定义为:

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{D(X)D(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}.$$

相关系数的性质

1. $-1 \leq \rho_{XY} \leq 1$ (可由 Cauchy-Schwarz 不等式证明);
2. $|\rho_{XY}| = 1 \iff X$ 与 Y 以概率 1 存在线性关系 $Y = aX + b$;
3. $|\rho_{XY}|$ 越接近 1, 线性相关程度越高; 越接近 0, 线性相关程度越低;
4. 对二维正态分布: 不相关 $\iff$ 独立 $\iff \rho = 0$ 。

§4.5 协方差矩阵

对于 n 维随机变量 $(X_1, \dots, X_n)$, 协方差矩阵 $\Sigma = (\sigma_{ij})_{n \times n}$, 其中

$$\sigma_{ij} = \text{Cov}(X_i, X_j) = E[(X_i - E(X_i))(X_j - E(X_j))].$$

协方差矩阵的性质:

- 对称矩阵: $\sigma_{ij} = \sigma_{ji}$;
- 半正定矩阵: 对任意向量 $\mathbf{a}$, $\mathbf{a}^T \Sigma \mathbf{a} \geq 0$;
- 对角元素为方差: $\sigma_{ii} = D(X_i)$ 。

n 维正态分布的重要特性

服从 n 维正态分布的随机变量, 其两两不相关性与相互独立性是等价的。这是正态分布特有的优良性质。

§4.6 独立与不相关的关系

独立与不相关的关系总结

1. 独立 $\Rightarrow$ 不相关 (由 $E(XY) = E(X)E(Y)$ 直接得到 $\text{Cov} = 0$);
2. 不相关 $\nRightarrow$ 独立 (不相关仅意味着没有线性关系, 但仍可能存在非线性关系);
3. 对于二维正态分布, 独立 $\iff$ 不相关 $\iff \rho = 0$ 。

【例题 4.4】(不相关但不独立的例子) 设 $X \sim N(0, 1)$, $Y = X^2$ 。则

$$\text{Cov}(X, Y) = E(X \cdot X^2) - E(X)E(X^2) = E(X^3) - 0 = 0,$$

故 X 与 Y 不相关。但 Y 完全由 X 决定, 显然不独立。

大数定律与中心极限定理

大数定律和中心极限定理是概率论中最重要的两类极限定理，前者揭示了大量随机现象的平均结果的稳定性，后者阐明了大量随机因素综合作用的结果近似服从正态分布。

§5.1
依概率收敛

依概率收敛

设 $\{X_n\}$ 为随机变量序列， X 为随机变量。若对任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\{|X_n - X| < \varepsilon\} = 1,$$

则称 $\{X_n\}$ 依概率收敛于 X ，记为 $X_n \xrightarrow{P} X$ 。

注. 依概率收敛是比通常的数列收敛更弱的一种收敛模式——它允许在小概率的情形下出现较大偏差。它可以被描述为“当 n 充分大时， X_n 与 X 有显著差异的事件发生的概率可以任意小”。

§5.2
大数定律 (LLN)

大数定律从理论上解释了“频率的稳定性”：当试验次数足够多时，随机事件的频率将稳定在其概率附近。

【定理 5.1】(Chebyshev 大数定律) 设 $\{X_k\}$ 为相互独立的随机变量序列，且具有相同的数学期望 $E(X_k) = \mu$ 和方差 $D(X_k) = \sigma^2 > 0$ ，则样本均值依概率收敛于 μ ：

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu.$$

即对任意 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| < \varepsilon \right\} = 1.$$

证明思路. 由 Chebyshev 不等式,

$$P \left\{ \left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| \geq \varepsilon \right\} \leq \frac{D(\frac{1}{n} \sum X_k)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0 \quad (n \rightarrow \infty).$$

□

【定理 5.2】(Bernoulli 大数定律) 设 μ_n 是 n 次 Bernoulli 试验中事件 A 发生的次数, $p = P(A)$, 则频率依概率收敛于概率:

$$\frac{\mu_n}{n} \xrightarrow{P} p.$$

注. Bernoulli 大数定律是 Chebyshev 大数定律的特例 (取 $X_k \sim B(1, p)$). 它将“频率的稳定性”这个经验事实上升为数学定理, 为统计中用频率估计概率提供了理论基础。

【定理 5.3】(Khinchin 大数定律) 设 $\{X_k\}$ 为独立同分布随机变量序列, 且 $E(X_k) = \mu$ 存在, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} \mu.$$

注. Khinchin 大数定律的优点在于: 只要求期望存在, 不要求方差存在。这使得它比 Chebyshev 大数定律有更广泛的适用范围。例如, 当随机变量服从期望存在但方差无穷的分布时, Khinchin 大数定律仍然成立。

§5.3 中心极限定理 (CLT)

中心极限定理是大数定律的深化: 它不仅说明了样本均值的稳定性, 还精确地描述了其误差的分布形态——正态分布。这是正态分布在概率统计中占据核心地位的根本原因。

【定理 5.4】(Lindeberg-Lévy 中心极限定理 (独立同分布情形)) 设 $X_1, X_2, \dots, X_n$ 相互独立, 服从同一分布, 且 $E(X_i) = \mu$, $D(X_i) = \sigma^2 > 0$ 。则当 n 充分大时, 和的标准化变量的分布函数趋于标准正态分布函数:

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n} \sigma} \leq y \right\} = \Phi(y).$$

等价表述:

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1), \quad \sum_{i=1}^n X_i \overset{\text{approx}}{\sim} N(n\mu, n\sigma^2).$$

【定理 5.5】(De Moivre–Laplace 中心极限定理 (二项分布的正态近似)) 设 $\mu_n \sim B(n, p)$, 则当 n 充分大时,

$$\lim_{n \rightarrow \infty} P\left\{\frac{\mu_n - np}{\sqrt{np(1-p)}} \leq x\right\} = \Phi(x).$$

注. 该定理表明: n 充分大时, 二项分布 $B(n, p)$ 可用正态分布 $N(np, np(1-p))$ 近似。一般经验法则是 $np \geq 5$ 且 $n(1-p) \geq 5$ 。

§5.4 中心极限定理的应用

【例题 5.6】(保险公司亏本概率) 某人寿保险公司有 $n = 10\,000$ 个同一年龄段的人参加保险。每人每年交保费 12 元。若一年内死亡, 家属可领取 1000 元。已知死亡率为 $p = 0.006$ 。求保险公司亏本的概率。

解. 设 X 表示一年内死亡人数, 则 $X \sim B(10\,000, 0.006)$ 。

$$\begin{aligned} E(X) &= np = 10\,000 \times 0.006 = 60, \\ D(X) &= np(1-p) = 10\,000 \times 0.006 \times 0.994 = 59.64, \\ \sqrt{D(X)} &= \sqrt{59.64} \approx 7.7227. \end{aligned}$$

保险公司利润: $Y = 10\,000 \times 12 - 1\,000X = 120\,000 - 1\,000X$ 。

亏本条件: $Y < 0 \iff 1\,000X > 120\,000 \iff X > 120$ 。

由 De Moivre–Laplace 中心极限定理, $\frac{X - 60}{7.7227} \overset{\text{approx}}{\sim} N(0, 1)$,

$$\begin{aligned} P\{X > 120\} &= 1 - P\{X \leq 120\} \\ &\approx 1 - \Phi\left(\frac{120 - 60}{7.7227}\right) \\ &= 1 - \Phi(7.77) \approx 0. \end{aligned}$$

故保险公司几乎不可能亏本。

【例题 5.7】(高尔顿钉板实验) 在一个钉板上, 大量小球自上而下通过层层排布的铁钉后, 最终落入底部的各个格子里。每个小球在每层遇到钉子时向左或向右的概率各为 $1/2$ 。经过 n 层钉子的独立碰撞后, 小球最终的位置近似服从正态分布 $N(n/2, n/4)$ 。这是中心极限定理最经典的物理演示。

中心极限定理的重要意义

- 1. 解释了正态分布的普遍性：实际中许多随机现象都可看作大量独立微小随机因素的叠加，因此近似服从正态分布；
- 2. 提供了近似计算方法：当样本量足够大时，可用正态分布近似计算原本复杂的概率（如二项分布、Poisson 分布等）；
- 3. 是统计推断的基础：抽样分布、区间估计、假设检验等统计方法的理论依据都离不开中心极限定理。

§5.5
大数定律与中心极限定理的比较

两者的区别与联系

方面	大数定律 (LLN)	中心极限定理 (CLT)
研究对象	样本均值 $\bar{X}_n$	标准化和 $\frac{\sum X_i - n\mu}{\sqrt{n}\sigma}$
结论类型	依概率收敛（定性）	依分布收敛（定量）
回答的问题	样本均值趋向何处？	波动服从什么分布？
数学形式	$\bar{X}_n \xrightarrow{P} \mu$	$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0,1)$
收敛速率	不提供	$O(1/\sqrt{n})$

直观理解：大数定律告诉我们“平均值会趋于期望”，中心极限定理进一步告诉我们“趋于期望的过程中，误差大约是正态分布的”。两者的关系类似于“单调有界数列必有极限”与“Taylor 展开”——前者给出存在性，后者给出精确的渐近表达式。

附录：补充知识

§.6 Γ 函数 (Gamma Function)

概率论中频繁出现的特殊函数：

$$\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0.$$

Γ 函数的基本性质

- 递推公式： $\Gamma(\alpha + 1) = \alpha \Gamma(\alpha)$ ；
- 与阶乘的关系： $\Gamma(n + 1) = n!$ (n 为正整数)；
- 特殊值： $\Gamma(1/2) = \sqrt{\pi}$ 。

Γ 函数在概率论中的应用包括：

- Γ 分布的概率密度中含有 $\Gamma(\alpha)$ 作为归一化常数；
- χ^2 分布是 Γ 分布的特例： $\chi^2(n) = \Gamma(n/2, 1/2)$ ；
- 正态分布的各阶矩计算中常出现 Γ 函数。

§.7 常用积分公式

$$\begin{aligned} \int_{-\infty}^{+\infty} e^{-x^2} dx &= \sqrt{\pi}, \\ \int_0^{+\infty} x^n e^{-\lambda x} dx &= \frac{n!}{\lambda^{n+1}} \quad (n \in \mathbb{N}, \lambda > 0), \\ \int_{-\infty}^{+\infty} e^{-ax^2+bx} dx &= \sqrt{\frac{\pi}{a}} \exp\left(\frac{b^2}{4a}\right), \quad a > 0. \end{aligned}$$

§.8 正态分布的矩

标准正态分布 $Z \sim N(0, 1)$, 利用对称性和分部积分可得:

$$\begin{aligned} E(Z) &= 0, & E(Z^2) &= 1, \\ E(Z^3) &= 0, & E(Z^4) &= 3, \\ E(Z^5) &= 0, & E(Z^6) &= 15. \end{aligned}$$

一般公式 (k 为正整数):

$$E(Z^{2k}) = (2k-1)!! = 1 \cdot 3 \cdot 5 \cdots (2k-1), \quad E(Z^{2k-1}) = 0.$$

§.9 重要分布的可加性

独立随机变量和的分布

1. 二项分布: $X \sim B(n_1, p)$, $Y \sim B(n_2, p)$ 独立, 则 $X + Y \sim B(n_1 + n_2, p)$;
2. Poisson 分布: $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ 独立, 则 $X + Y \sim P(\lambda_1 + \lambda_2)$;
3. 正态分布: $X_i \sim N(\mu_i, \sigma_i^2)$ 独立, 则 $\sum a_i X_i \sim N(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2)$;
4. χ^2 分布: $X_i \sim N(0, 1)$ 独立, 则 $\sum_{i=1}^n X_i^2 \sim \chi^2(n)$;
5. 指数分布: $X_i \sim E(\lambda)$ 独立, 则 $\sum_{i=1}^n X_i \sim \Gamma(n, \lambda)$ 。

§.10
常用分布的期望与方差总表

分布	记号	$E(X)$	$D(X)$
两点分布	$B(1, p)$	p	$p(1-p)$
二项分布	$B(n, p)$	np	$np(1-p)$
Poisson 分布	$P(\lambda)$	λ	λ
几何分布	$G(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
均匀分布	$U(a, b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
指数分布	$E(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
正态分布	$N(\mu, \sigma^2)$	μ	σ^2

§.11
独立与不相关的区别

独立与不相关的辨析

1. 独立 $\Rightarrow$ 不相关 ($E(XY) = E(X)E(Y)$ 推出 $\text{Cov} = 0$);
2. 不相关 $\nRightarrow$ 独立 (不相关仅意味着没有线性关系, 仍可能存在非线性关系);
3. 对于二维正态分布: 独立 $\iff$ 不相关 $\iff \rho = 0$;
4. 相关系数只度量线性相关程度, 不能检测非线性依赖 (如 $Y = X^2$)。