
R 语言自学笔记

R



魏舟

2026 年 8 月 13 日

目录

1	R 语言简介	5
1.1	安装网址	5
1.2	界面操作示例	7
1.3	一个简单的示例 (不是 Hello World)	7
2	R 语言预备知识	9
2.1	基本命令	9
2.1.1	获取工作目录	9
2.1.2	设置工作目录	9
2.1.3	注释	9
2.1.4	变量名的命名	10
2.1.5	赋值	10
2.1.6	变量的显示	10
2.1.7	查看与清除变量	10
2.1.8	函数帮助文档查询	11
2.1.9	软件的退出与保存	11
2.1.10	保存数据	11
2.2	R 语言语法	12
2.2.1	函数	12
2.2.2	向量 (Vector)	15
2.2.3	NA 与 NULL 值	18
2.2.4	矩阵 (Matrix)	18
2.2.5	列表 (List)	20
2.2.6	数据框 (Data Frame)	22
2.2.7	因子 (Factor)	23
2.2.8	常用数学与统计函数	24
2.3	控制流与自定义函数	25
3	数据分析	29
3.1	数据清洗与转换 (dplyr & tidyr)	29
3.1.1	dplyr 的核心动作 (Verbs)	29

3.1.2	tidyr 的数据重塑	29
3.1.3	常用清洗函数对比总结	29
3.2	数据可视化 (ggplot2)	29
3.2.1	ggplot2 的基础语法结构	30
3.2.2	常见图表类型 (Geoms)	30
3.2.3	图形美化：颜色、标签与主题	30
3.2.4	分面 (Faceting)	31
3.2.5	常用外观调整函数对照表	31
3.3	统计检验基础	31
3.3.1	均值比较 (T-Test & ANOVA)	32
3.3.2	相关性与回归分析	32
3.3.3	常用统计函数速查表	32

Chapter 1

R 语言简介

R 语言不仅是一门编程语言，更是数据科学领域处理复杂统计逻辑的专业环境。其核心竞争力在于将严谨的数学模型与出版级的数据可视化（Data Visualization）完美融合。不同于通用编程语言，R 的设计哲学高度契合数学直觉，例如在处理标准正态分布 $N(0,1)$ 的概率密度计算时：

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (1.1)$$

开发者仅需调用 `dnorm(x)` 即可实现。

在图形生成方面，R 的 `ggplot2` 扩展包基于“图形语法”理论，允许用户通过图层叠加的方式构建极其复杂的视觉表达。如下代码展示了如何快速生成带有线性拟合带的专业散点图：

```
1 library(ggplot2)
2 # 使用内置数据集绘制：散点 + 线性回归趋势线
3 ggplot(mtcars, aes(x=wt, y=mpg)) +
4   geom_point(color="steelblue", size=2) +
5   geom_smooth(method="lm", se=TRUE, col="indianred") +
6   theme_minimal() +
7   labs(title="Weight vs. MPG Regression", x="Weight", y="Miles/Gallon")
```

通过这种“声明式”的编程方式，R 极大地缩短了从原始数据到学术洞察的路径。无论是进行大规模基因序列分析，还是金融市场的波动率建模，R 凭借 CRAN 镜像站中超过两万个专业扩展包的支持，始终占据着统计科研领域的统治地位。

1.1 安装网址

网址如下，

R 语言安装网址

<https://cran.r-project.org/>

IDE 安装网址

<https://posit.co/download/rstudio-desktop/>

注意安装路径选择全英文

1.2 界面操作示例




图 1.1: R studio 操作界面

1.3 一个简单的示例 (不是 Hello World)

```

1 # Listing 1.1 - A Sample R session
2 age <- c(1,3,5,2,11,9,3,9,12,3)
3 weight <- c(4.4,5.3,7.2,5.2,8.5,7.3,6.0,10.4,10.2,6.1)
4 mean(weight)
5 sd(weight)
6 cor(age,weight)
7 plot(age,weight)

```


Chapter 2

R 语言预备知识

2.1 基本命令

2.1.1 获取工作目录

使用 `getwd()` 函数获取当前工作目录，作用是查看当前工作目录在哪一个具体位置，C 盘或者是其他，第一次使用可能会出现警告，但是也可以看到工作目录，你可以在运行一次代码，如下：

```
1 > getwd()
2 [1] "C:/Users/橙/Documents"
3 Warning message:
4 In normalizePath(path.expand(path), winslash, mustWork) :
5   path[1]="C:/Users/?/Documents": 文件名、目录名或卷标语法不正确。
6 > getwd()
7 [1] "C:/Users/橙/Documents"
```

2.1.2 设置工作目录

使用 `setwd()` 函数更改当前目录，把工作目录更改到你存放你需要使用的数据包的那个位置，更便于直接重工作目录中读取，否则需要使用全路径。在使用函数是需要几点注意，请看以下代码：

```
1 > setwd("F:\\R.cx")#工作目录的地址需要用双引号括起来，注意斜杠，这种单斜杠会报错
2 Error: '\\R' is an unrecognized escape in character string starting "F:\\R"
3 > setwd("F:/R.cx")#这种单斜杠可以，能运行
4 > setwd("F://R.cx")#这行与下一行的双斜杠都行
5 > setwd("F:\\R.cx")
6 >
```

2.1.3 注释

R 语言的注释使用 `#` 号，写代码一定要常写注释，不然时间久了会忘记某代码的作用，便于后续操作。在 Rstudio 中可以使用 `Ctrl+shift+C` 进行多行注释。

2.1.4 变量名的命名

与其他语言的变量名命名差不多，主要要注意：数字不能开头；% 号是非法字符，不可以用来命名；. 号后面不可以跟数字；不可以下划线开头。变量名可以为与你操作相关的名字命名，如我要对一行身高的数据求均值：

```
1 highth<-c(175,169,179,175,180,183)
2 highth_mean<-mean(highth)#对身高求均值
```

2.1.5 赋值

R 语言的赋值方式与其他语言有点区别，有三种，分别是左箭头 <-（< 键 +-键（等号左边的那个，不要按 Shift）），等号 =，右箭头->，如：

```
1 > a<-2
2 > b=3
3 > c->4 #注意右箭头使用方法，被赋值的应该在右边，简单点说，就是某某赋值给谁，箭头就指向谁
4 Error in 4 <- c : invalid (do_set) left-hand side to assignment
5 > 4->c
6 > a #键盘敲出变量名，回车后就会显示结果
7 [1] 2
8 > b
9 [1] 3
10 > c
11 [1] 4
12 >
```

2.1.6 变量的显示

1. 命令行直接输入变量名

2. 利用 print() 函数，如下

```
1 > a<-2
2 > a #命令行直接输入变量名
3 [1] 2
4 > print(a) #利用print()函数
5 [1] 2
```

2.1.7 查看与清除变量

查看变量：ls()

清除指定变量: `rm()`

清除所有变量: `rm(list = ls())` 如下:

```
1 > ls()      #查看变量, 这个函数是查看所有已定义的变量, 输出所有变量名
2 [1] "a" "b" "c"
3 > rm(a)     #清除变量a
4 > rm(list=ls()) #清除所有变量
```

2.1.8 函数帮助文档查询

当遇到一个函数不会用时, 可以使用帮助文档查询, 结果会在 Rstudio 的右下角框里显示, 方法有三种:

1. ?+ 要查询的函数

2. 使用 `help()` 函数查询

3. 使用 `example()` 函数查询

我以求和函数 `sum()` 为例:

```
1 > ?sum
2 > help(sum)
3 > example(sum)
```

2.1.9 软件的退出与保存

1. 可以直接输入 `q()` 函数; 也可以右上角直接叉掉, 后根据提示操作

2. 当写完一个文件时, 可以点击保存按钮, 根据提示选择保存位置, 文件后缀有多种, 看你保存哪种文件, 有 .R、.Rdata 等后缀, .R 一般是保存代码的, .Rdata 是保存处理后的数据的。

2.1.10 保存数据

可以使用 `save()` 函数, 可以保存多种格式的文件

```
1 > save(b, file="xxx.Rdata") #保存b, 文件是xxx, 格式为.Rdata
2 > save(b, c, file="xxx.Rdata") #保存b, c, 文件是xxx, 格式为.Rdata
3 > save.image("xxx.Rdata") #保存所有(你定义的所有变量及数据), 文件是xxx, 格式为.Rdata
```

2.2 R 语言语法

2.2.1 函数

R 中含有大量的函数，比如求和函数 `sum()`，求均值 `mean()` 等直接可以拿来使用的函数，但是往往在实际操作过程中，因为需求不同需要自己写函数，就是自定义函数，类似于 C 或 C++ 中的自定义函数，我们来看一下 R 中如何自定义函数，请看如下代码：

```
1 > #函数名<-function(){.....}
2 > f<-function(a,b) #写一个求和函数,function()是固定格式
3 + {
4 +   k<-a+b
5 +   return(k)      #返回结果为k，如果没有设置返回值，则函数会返回最后一行执行的
                     #结果
6 + }
7 > f(3,4)           #使用函数名加一个括号调用函数
8 [1] 7
```

注：函数可以套函数使用

输出函数

`print()` 函数，输出，与 C 语言中的 `printf()` 函数作用一样

```
1 > print(5)
2 [1] 5
```

安装 R 包

安装 R 包需要使用 `install.packages()` 或者 `BiocManager::install()` 函数安装，`library()` 函数调用，以安装 `openxlsx` 为例，如下：

```
1 安装R包代码如下
2 install.packages("openxlsx")
3 或BiocManager::install("openxlsx")
4 library(openxlsx)
```

文件的读取

在 R 语言中，读取文件是数据分析的第一步。根据文件格式（txt, csv, xlsx）和数据结构的复杂度，我们可以选择不同的函数。以下是几种常用的读取函数及其参数详解：

1. `scan()` 函数：适用于读取简单的数值、字符序列或大规模规则数据。

- **file**: 文件路径字符串。注意 Windows 路径需用 "/" 或 "

"。

- **what**: 指定数据类型, 如 `double()`, `integer()`, `character()`。
- **sep**: 分隔符, 默认为空字符 (空格、制表符、换行符均可)。

```
1 # 读取纯数字
2 x <- scan(file = "data.txt", what = double())
3 # 读取混合类型 (作为字符读入)
4 y <- scan(file = "mixed.txt", what = "")
```

Listing 2.1: scan 函数示例

2. `readline()` 函数: 主要用于交互式脚本, 从控制台读取单行输入。

- **prompt**: 打印在终端的提示信息。

```
1 name <- readline(prompt = "请输入您的姓名: ")
2 print(paste("你好,", name))
```

3. `readLines()` 函数: 用于以“行”为单位读取文本文件。

- **n**: 读取的行数。
- **encoding**: 字符编码方式 (如 "UTF-8"), 解决中文乱码的关键。

```
1 # 读取前三行内容
2 txt_content <- readLines("memo.txt", n = 3, encoding = "UTF-8")
```

4. `read.table()` 函数: 读取结构化表格数据的“万能钥匙”。

- **header**: 逻辑值, 首行是否包含列名。
- **sep**: 字段分隔符。常见: `","` (CSV), `"\t"` (Tab 间隔)。
- **na.strings**: 指定代表缺失值的字符。

```
1 # 读取带有表头、逗号分隔、且将"999"视为缺失值的文件
2 my_data <- read.table("survey.txt", header = TRUE, sep = ",", na.strings = "
  999")
```

5. `read.csv()` 函数: `read.table` 的变体, 专为逗号分隔文件优化。

```
1 # 默认 header = TRUE
2 df <- read.csv("results.csv")
```

6. `read.xlsx()` 函数: 读取 Excel 文件的标准方案 (需 `openxlsx` 包)。

```
1 library(openxlsx)
2 excel_data <- read.xlsx("report.xlsx", sheet = 1, startRow = 2)
```

函数	主要用途	返回类型	适用场景
scan	快速读取元素	向量/列表	大规模数值或简单序列
readline	交互式输入	长度为 1 的字符向量	脚本运行中的人工干预
readLines	按行读取文本	字符向量	文本挖掘或非结构化数据
read.table	读取结构化表格	数据框 (data.frame)	绝大多数实验原始数据
read.xlsx	读取 Excel 文件	数据框 (data.frame)	现成的统计报表

常用读取函数对比表

注意事项： 在读取文件前，建议先使用 `getwd()` 查看当前工作目录，或使用 `setwd()` 设置路径，这样在 `file` 参数中只需写文件名即可，能极大简化代码。

文件的输出

在 R 语言中，将处理好的数据或结果保存到本地文件，主要使用以下几种函数：

- 1. **write.table()** 函数：与 `read.table()` 对应，用于将数据框或矩阵输出为结构化文本文件。
 - `x`: 要写入的对象。
 - `file`: 保存路径。
 - `append`: 逻辑值。若为 `TRUE`，则在原文件末尾追加；若为 `FALSE`，则覆盖原文件。
 - `sep`: 分隔符，如 `sep = ","` 表示保存为 CSV 格式。
 - `row.names/col.names`: 是否保留行名或列名（通常建议设为 `FALSE` 以保持纯净的数据格式）。

- 2. **write()** 函数：常用于将向量数据以特定列数写入文件。

```
1 # 将字符串写入桌面文件
2 write("Hello, world", "C:/Users/橙/Desktop/juli.txt")
```

- 3. **cat()** 函数：功能强大的输出函数，可以将多个对象拼接并直接写入文件。
 - `file`: 指定输出文件的路径。
 - `append`: 控制写入模式。
 - `append = TRUE` (或 `T`): 追加写入，在文件原有内容后添加。
 - `append = FALSE` (或缺省): 覆盖写入，删除原文件内容并重新写入。

```
1 # 追加写入示例
2 cat("hello world", file="C:/Users/橙/Desktop/juli.txt", append=TRUE)
```

```

3
4 # 覆盖写入示例
5 cat("hello world", file="C:/Users/橙/Desktop/juli1.txt")

```

4. **write.csv()** 函数：专用于输出逗号分隔文件的便捷函数。

- 默认 `sep = ","` 且 `col.names = TRUE`。

5. **save()** / **saveRDS()** 函数：用于保存 R 特有的二进制格式（.RData / .rds），适合保存模型或中间变量。

函数	输出对象类型	主要特点
<code>write.table</code>	数据框 / 矩阵	参数丰富，兼容性最强
<code>write</code>	向量	简单快捷，常用于简单列表
<code>cat</code>	字符串 / 拼接对象	灵活，支持追加/覆盖两种模式
<code>write.csv</code>	数据框	自动化设置，常用于 Excel 交互

输出函数对比总结

温馨提示： 在输出数据到 CSV 时，若不想让第一列出现行索引数字，请务必加上参数 `row.names = FALSE`。

2.2.2 向量 (Vector)

向量是 R 语言中最基本的数据结构，其特点是所有元素必须属于同一类型（数值型、字符型或逻辑型）。

1. 向量的创建

- **c()** 函数：最常用的组合函数（combine），用于连接元素。
- **assign()** 函数：较少用，等同于赋值符号。

```

1 x <- c(1, 3, 5, 7)           # 数值向量
2 y <- c("Apple", "Banana")    # 字符向量
3 assign("z", c(1, 2))         # 等同于 z <- c(1, 2)

```

2. 创建等差序列

- 冒号运算符 (`:`)：生成步长为 1 的序列。
- **seq()** 函数：生成等差序列，可指定步长（`by`）或长度（`length.out`）。
- **rep()** 函数：生成重复序列。

```

1 a <- 1:10                # 1 到 10
2 b <- seq(from=1, to=10, by=2) # 1, 3, 5, 7, 9
3 c <- rep(1:3, times=2)     # 1, 2, 3, 1, 2, 3
4 d <- rep(1:3, each=2)      # 1, 1, 2, 2, 3, 3

```

3. 向量的索引 (Indexing) R 的索引从 1 开始, 这与 Python/C 不同。

- 正整数索引: 提取对应位置元素。
- 负整数索引: 剔除对应位置元素。
- 逻辑索引: 提取满足条件 (TRUE) 的元素。
- 名称索引: 若向量有 names, 可按名提取。

```

1 v <- c(10, 20, 30, 40, 50)
2 v[2]          # 提取第2个: 20
3 v[c(1, 3)]    # 提取第1和第3个: 10, 30
4 v[-1]         # 剔除第1个: 20, 30, 40, 50
5 v[v > 35]     # 提取大于35的: 40, 50

```

4. 向量元素的更改通过索引选中特定位置的元素, 并使用赋值符号 <- 将新值赋给它。

```

1 v <- c(10, 20, 30, 40)
2 v[2] <- 200      # 将第2个元素修改为 200
3 v[v < 35] <- 0    # 将所有小于 35 的元素统一修改为 0
4 v[c(1, 3)] <- c(8, 9) # 同时修改第1和第3个元素

```

5. 向量元素的删除 R 语言中“删除”元素的本质是: 创建一个不包含该元素的新向量并覆盖原变量。

- 按位置删除: 使用负索引。
- 按值删除: 利用逻辑判断结合 != (不等于) 或 %in% (包含于)。
- 全部清空: 将变量赋值为 NULL。

```

1 v <- c("A", "B", "C", "D", "E")
2
3 # 1. 删除特定位置元素
4 v <- v[-2]          # 删除第2个元素 "B"
5 v <- v[-c(1, 3)]    # 同时删除此时的第1和第3个元素
6
7 # 2. 按值删除
8 v <- v[v != "E"]     # 提取所有不等于 "E" 的元素, 达到删除 "E" 的效果
9
10 # 3. 删除特定范围的元素
11 nums <- 1:10
12 nums <- nums[!(nums %in% c(2, 4, 6))] # 删除 2, 4, 6

```


6. 向量的扩展可以通过为超出当前长度的索引赋值来动态扩展向量。

```
1 v <- c(1, 2)
2 v[4] <- 10           # v 变为 c(1, 2, NA, 10), 中间会自动补 NA
```

7. 向量化运算 (Vectorized Operation) R 的一大特色是运算符会作用于向量的每一个元素。

```
1 x <- c(1, 2, 3)
2 y <- c(10, 20, 30)
3 x + y           # 结果: 11, 22, 33
4 x * 2           # 结果: 2, 4, 6
```

类别	函数	功能说明
属性查询	length(x)	返回向量的长度（元素个数）
	mode(x)	返回向量的数据类型（如 numeric, character）
	names(x)	获取或设置向量元素的名称
统计汇总	sum(x)	向量元素求和
	mean(x)	向量元素求平均值
	max(x) / min(x)	返回向量中的最大值 / 最小值
	sd(x) / var(x)	返回向量的标准差 / 方差
排序与转换	sort(x)	对向量进行排序（默认为升序）
	rev(x)	将向量元素完全反转
	unique(x)	去除向量中的重复元素，仅保留唯一的项
	order(x)	返回排序后的元素在原向量中的索引位置
搜索与逻辑	which(x == a)	返回符合条件 a 的元素下标（位置）
	which.max(x)	返回最大值所在的第一个位置索引
	is.na(x)	检测缺失值，返回逻辑向量（TRUE/FALSE）
	any() / all()	判断向量中是否存在 / 是否全部为 TRUE
数据清洗	na.omit(x)	移除向量中的所有缺失值 (NA)
	round(x, n)	将数值四舍五入保留 n 位小数

常用向量函数汇总表

注意事项： 如果将不同类型的数据放入同一个向量，R 会进行“隐式转换”（Coercion），转换顺序通常为：Logical < Integer < Double < Character。例如 c(1, "A") 会导致 1 被转换为字符型 "1"。

2.2.3 NA 与 NULL 值

在 R 语言中，NA 和 NULL 都有“空”的含义，但在处理逻辑和数据结构中有着本质的区别。

1. **NA (Not Available)** NA 表示内容缺失。它是一个“占位符”，代表该位置应该有值，但目前不知道是多少。

- **特点：**NA 具有长度（长度为 1），且有类型之分（如 `NA_integer_`, `NA_character_`）。
- **逻辑运算：**任何与 NA 进行的算术运算结果通常仍为 NA（例如 `1 + NA = NA`）。

2. **NULL (Null Object)** NULL 代表一个空对象。它表示“什么都没有”，连占位符都不是。

- **特点：**NULL 的长度始终为 0，不占用向量空间。
- **用途：**常用于初始化一个空变量，或者从列表（List）中彻底删除某个元素。

3. **常用检测与处理函数**注意：NA 不能使用 `==` 进行判断，必须使用专用函数 `is.na()`。

```
1 x <- c(1, 2, NA, 4)
2 is.na(x)           # 返回逻辑向量：FALSE FALSE TRUE FALSE
3 anyNA(x)           # 快速检查是否存在缺失值：TRUE
4
5 y <- NULL
6 is.null(y)         # 检查是否为NULL：TRUE
```

4. **向量中的行为对比**这是理解两者差异最直观的方式：

```
1 # NA 占据位置，作为元素存在
2 v_na <- c(1, NA, 3)
3 length(v_na)       # 结果为 3
4
5 # NULL 不占位置（在组合时被忽略）
6 v_null <- c(1, NULL, 3)
7 length(v_null)     # 结果为 2
```

NA 与 NULL 核心差异表

进阶提示： 在进行统计计算（如 `sum()`, `mean()`）时，如果向量包含 NA，结果默认会变成 NA。此时需要显式设置参数 `na.rm = TRUE` 来剔除缺失值后再计算：`mean(x, na.rm = TRUE)`。

2.2.4 矩阵 (Matrix)

矩阵是一个二维的数据结构，可以看作是排列成行和列的向量。

1. **矩阵的创建**使用 `matrix()` 函数，通过指定数据向量、行数或列数来创建。

- **data:** 包含矩阵元素的向量。

维度	NA (缺失值)	NULL (空对象)
含义	存在但未知 (Missing value)	不存在该对象 (Undefined)
长度	1	0
类型示例	NA_integer_, NA_character_	唯一的 NULL 类
运算	1 + NA = NA	1 + NULL = numeric(0)
检测函数	is.na()	is.null()
数据框行为	在表格中显示为单元格空白/NA	无法作为独立列存在

- **nrow / ncol**: 设定的行数和列数。
- **byrow**: 逻辑值。若为 TRUE，则按行填充数据；默认为 FALSE（按列填充）。

```

1 # 创建一个 2 行 3 列的矩阵
2 m1 <- matrix(1:6, nrow = 2, ncol = 3)
3 # 按行填充
4 m2 <- matrix(1:6, nrow = 2, byrow = TRUE)

```

2. 矩阵的合并与维度命名

- **rbind()**: 将多个向量或矩阵按行合并。
- **cbind()**: 将多个向量或矩阵按列合并。
- **dimnames**: 设置行名和列名。

```

1 v1 <- c(1, 2); v2 <- c(3, 4)
2 m_row <- rbind(v1, v2) # 2行2列
3 colnames(m_row) <- c("Col1", "Col2")
4 rownames(m_row) <- c("Row1", "Row2")

```

3. 矩阵的索引 (Indexing) 使用 [行索引, 列索引] 的格式。

```

1 m <- matrix(1:9, nrow = 3)
2 m[1, 2]      # 提取第 1 行第 2 列的元素
3 m[1, ]       # 提取第 1 行所有元素（返回向量）
4 m[, 2:3]     # 提取第 2 到 3 列所有元素
5 m[-1, ]     # 删除第 1 行后的剩余部分

```

4. 常用矩阵运算函数矩阵运算在 R 中非常高效。

```

1 t(m)          # 矩阵转置
2 diag(m)       # 提取对角线元素
3 m * m         # 元素级乘法（对应位置相乘）
4 m %*% m       # 线性代数中的矩阵乘法
5 colSums(m)    # 对每一列求和
6 rowMeans(m)   # 对每一行求平均值

```

函数	功能说明	返回值示例
dim(m)	获取矩阵的维度（行数和列数）	c(nrow, ncol)
nrow(m)	单独获取行数	整数
ncol(m)	单独获取列数	整数
attributes(m)	查看矩阵的所有元数据（如维度、行列名）	列表

矩阵核心属性函数表

进阶提示： 1. 如果对矩阵进行索引时只取一行或一列，结果默认会退化（Drop）为向量。如果不希望退化，请使用 `m[1, , drop = FALSE]`。2. 矩阵本质上是一个带有维度属性（`dim`）的向量，因此 `length(m)` 返回的是矩阵中元素的总个数。

2.2.5 列表 (List)

列表是 R 语言中最复杂的数据结构，它可以包含不同类型的对象，且对象之间的长度可以不同。

1. 列表的创建使用 `list()` 函数创建，建议在创建时为每个成分命名，方便后续调用。

```

1 # 创建包含向量、矩阵和字符串的列表
2 my_list <- list(
3   vec = c(1, 2, 3),
4   mat = matrix(1:4, nrow = 2),
5   msg = "Hello R"
6 )

```

2. 列表的索引 (关键点) 访问列表元素有两种常用的方式，其返回结果完全不同：

- 单方括号 `[ ]`：提取列表的 ** 子集 **，结果仍为一个“小列表”。
- 双方括号 `[[ ]`：提取列表中的 ** 具体内容 **，结果为该位置原始的对象类型。
- 美元符号 `$`：按名称提取内容，效果等同于 `[[ ]`。

```
1 my_list[1]      # 返回一个只含向量的列表
2 my_list[[1]]    # 返回具体的数值向量：1, 2, 3
3 my_list$vec     # 同上，返回数值向量
```

3. 列表元素的更改与添加

```
1 # 修改元素
2 my_list[[3]] <- "Goodbye"
3
4 # 添加新元素
5 my_list$new_item <- c(TRUE, FALSE)
6
7 # 删除元素：赋值为 NULL
8 my_list$msg <- NULL
```

4. 列表的合并与转换

```
1 # 合并列表
2 combined_list <- c(list1, list2)
3
4 # 将列表转换为向量（若类型一致）
5 v <- unlist(my_list)
```

操作	语法	结果说明
提取子集	L[i]	返回一个列表，包含第 i 个元素
提取内容	L[[i]]	返回第 i 个元素本身的类型（向量/矩阵等）
按名提取	L\$name	与 L[["name"]] 等价，最常用的方式
元素个数	length(L)	返回列表中顶层成分的数量
查看结构	str(L)	极其重要： 显示列表的层级和内容结构

列表核心操作汇总表

进阶提示： 1. 为什么需要双括号？想象列表是一个装着许多盒子的货车，L[1] 是卸下了第一辆货车上的第一个“盒子”，而 L[[1]] 则是打开了盒子，拿到了里面的“货物”。2. str() 函数：面对复杂的统计模型输出结果（通常是多层嵌套列表），使用 str() 是理清数据脉络的第一步。

2.2.6 数据框 (Data Frame)

数据框是 R 中最常用的数据结构，用于存储表格状数据。

1. 数据框的创建使用 `data.frame()` 函数，将多个向量组合成列。

```
1 # 创建一个包含病患信息的数据框
2 patient_id <- c(101, 102, 103)
3 age <- c(25, 42, 37)
4 treatment <- c("A", "B", "A")
5
6 df <- data.frame(ID = patient_id, Age = age, Group = treatment)
```

2. 查看数据框属性对于大型数据集，直接输入变量名查看是不现实的。

- `head(df, n)`: 查看前 `n` 行（默认为 6 行）。
- `tail(df, n)`: 查看后 `n` 行。
- `dim(df)`: 获取行数和列数。
- `str(df)`: 查看数据框结构（各列类型及前几个值）。
- `summary(df)`: 获取每列的统计摘要（最大、最小、均值等）。

3. 数据框的索引与提取

```
1 # 1. 访问列
2 df$Age           # 返回 Age 列的向量
3 df[["Age"]]      # 同上
4 df[, 2]          # 提取第 2 列
5
6 # 2. 访问行
7 df[1, ]          # 提取第 1 行
8
9 # 3. 逻辑筛选（极其常用）
10 # 提取 Group 为 "A" 的所有病患行
11 group_a <- df[df$Group == "A", ]
```

4. 数据框的修改与合并

```
1 # 添加新列
2 df$Gender <- c("M", "F", "M")
3
4 # 修改列名
5 colnames(df)[3] <- "Treatment_Group"
6
7 # 合并
8 # rbind(df1, df2) 合并行（列名需一致）
9 # cbind(df1, df2) 合并列（行数需一致）
```

函数	功能说明	备注
<code>nrow(df)</code>	返回行数	对应观察对象数
<code>ncol(df)</code>	返回列数	对应变量数
<code>names(df)</code>	获取列名	等价于 <code>colnames()</code>
<code>subset()</code>	按条件提取子集	<code>subset(df, Age > 30)</code>
<code>with()</code>	简化列名引用	<code>with(df, mean(Age))</code>

数据框处理常用函数表

进阶提示： 1. 字符与因子：在旧版 R 中，创建数据框时字符会自动转为因子（Factor）。现代版本（R 4.0+）默认不再转换。若需手动控制，可设置 `stringsAsFactors = TRUE`。2. 缺失值处理：使用 `na.omit(df)` 可以快速删除数据框中所有包含 NA 的行。

2.2.7 因子 (Factor)

因子用于存储分类变量。在 R 内部，因子被存储为整数向量，并带有一个标签（Label）向量。

1. 因子的创建使用 `factor()` 函数。

- **levels**: 手动指定分类的水平。如果不指定，R 会按字母顺序排列。
- **labels**: 为水平设置更直观的标签。

```
1 # 创建简单因子
2 gender <- factor(c("Male", "Female", "Female", "Male"))
3 # 查看因子水平
4 levels(gender) # 结果为 "Female" "Male"
```

2. 有序因子 (Ordered Factor) 用于有明显等级顺序的数据（如：病情的轻、中、重）。

```
1 status <- c("Low", "High", "Medium", "High", "Low")
2 # 指定等级顺序，否则默认按字母排序 (High, Low, Medium)
3 status_factor <- factor(status,
4                           ordered = TRUE,
5                           levels = c("Low", "Medium", "High"))
```

3. 常用函数与操作

```
1 # 1. 频数统计
2 table(gender)      # 统计每个水平出现的次数
3
4 # 2. 修改因子水平
```

```

5 levels(gender) <- c("F", "M") # 将 Female/Male 简写
6
7 # 3. 将连续变量因子化 (分组)
8 age <- c(22, 45, 18, 65, 30)
9 age_group <- cut(age, breaks = c(0, 18, 60, Inf),
10                  labels = c("Minor", "Adult", "Senior"))

```

函数	功能说明	备注
is.factor()	检查对象是否为因子	返回逻辑值
levels()	获取或设置因子的水平	返回字符向量
nlevels()	返回因子的水平个数	等价于 length(levels())
as.factor()	将其他类型强制转换为因子	不支持指定顺序
gl()	生成规则的因子序列	gl(n, k) 生成 n 个水平, 每水平重复 k 次

因子相关常用函数表

进阶提示：数值型因子的“陷阱” 如果一个因子是由数字组成的（例如 `f <- factor(c(10, 20, 30))`），直接使用 `as.numeric(f)` 会返回其内部的 ** 层级索引 **（1, 2, 3）而不是原本的数字。正确转换方法：`as.numeric(as.character(f))`。

2.2.8 常用数学与统计函数

R 语言内置了极其丰富的数学与统计工具，能够高效处理向量化数据。

1. 基本数学函数这些函数通常作用于向量中的每一个元素。

```

1 abs(-5)           # 绝对值: 5
2 sqrt(16)          # 开平方: 4
3 exp(1)            # 指数函数: 2.718...
4 log(100, base=10) # 对数函数, 默认以 e 为底
5 round(3.1415, 2)  # 四舍五入保留两位小数: 3.14
6 ceiling(3.1)      # 向上取整: 4
7 floor(3.9)        # 向下取整: 3

```

2. 统计汇总函数用于描述性统计分析。注意：若数据中包含 NA，需添加 `na.rm = TRUE`。

```

1 x <- c(1, 5, 10, 20, NA)
2 sum(x, na.rm = TRUE) # 求和
3 mean(x, na.rm = TRUE) # 算术平均值
4 median(x, na.rm = TRUE) # 中位数

```



```

5 var(x, na.rm = TRUE)      # 方差
6 sd(x, na.rm = TRUE)       # 标准差
7 range(x, na.rm = TRUE)    # 极差 (返回最小值和最大值)
8 quantile(x, 0.75, na.rm = TRUE) # 计算 75% 分位数

```

3. 概率分布函数 (以正态分布为例) R 中对每种分布都有四类函数, 其前缀分别为:

- **d** (density): 密度函数 / 概率质量函数。
- **p** (probability): 累积分布函数 (左尾概率)。
- **q** (quantile): 分位数函数 (**p** 的反函数)。
- **r** (random): 生成符合该分布的随机数。

```

1 rnorm(100, mean = 0, sd = 1) # 生成 100 个标准正态分布随机数
2 pnorm(1.96)                  # 标准正态分布下, Z < 1.96 的概率 (约 0.975)
3 qnorm(0.95)                  # 找到对应 95% 累积概率的 Z 值 (约 1.64)

```

分布类型	R 函数名后缀	典型应用场景
正态分布 (Normal)	norm	绝大多数连续变量分析
T 分布 (Student's t)	t	小样本均值检验
二项分布 (Binomial)	binom	患病/未患病等二分类实验
泊松分布 (Poisson)	pois	罕见事件发生次数统计
卡方分布 (Chi-squared)	chisq	计数资料的关联性检验

常用分布函数名对照表

进阶提示: 在进行统计绘图或模拟实验时, 如果希望结果具有可重复性, 请务必在生成随机数前使用 `set.seed(数值)` 函数设置随机数种子 (如 `set.seed(123)`)。

2.3 控制流与自定义函数

控制流用于管理代码的执行逻辑, 而函数则将一系列操作封装成一个可重复调用的单元。

1. 条件判断 (If-Else) 用于根据逻辑条件的真假执行不同的代码块。

```

1 x <- 85
2 if (x >= 90) {
3   print("优秀")
4 } else if (x >= 60) {
5   print("合格")

```

```
6 } else {  
7     print("不合格")  
8 }  
9  
10 # 向量化版本: ifelse() 函数 (极其常用)  
11 # 语法: ifelse(test, yes, no)  
12 status <- ifelse(x >= 60, "Pass", "Fail")
```

2. 循环结构 (Loop)

- **for** 循环: 遍历向量或列表中的每一个元素。
- **while** 循环: 当条件满足时持续运行。

```
1 # for 循环示例  
2 for (i in 1:5) {  
3     print(i^2)  
4 }  
5  
6 # 批量处理文件名示例  
7 files <- c("sample1.csv", "sample2.csv")  
8 for (f in files) {  
9     # data <- read.csv(f)  
10    # ... 处理代码 ...  
11 }
```

3. 自定义函数 (Function) 函数允许你将复杂的逻辑打包。R 函数会自动返回最后一行表达式的结果。

```
1 # 定义函数语法: 函数名 <- function(参数1, 参数2, ...) { 逻辑体 }  
2 calc_bmi <- function(weight, height) {  
3     bmi <- weight / (height^2)  
4     return(bmi) # 显式返回, 也可以省略直接写 bmi  
5 }  
6  
7 # 调用函数  
8 my_bmi <- calc_bmi(70, 1.75)
```

控制流常用关键字与技巧表

进阶提示: 避免“显式循环” R 语言是向量化语言。在处理大型数据框时, 尽量使用 `ifelse()` 或 `apply` 系列函数 (如 `lapply`, `sapply`), 而不是直接写 `for` 循环。这不仅能让代码更简洁, 还能显著提升运行速度。

关键字	功能说明	应用场景
if / else	标准条件分支	针对单个逻辑判断
ifelse()	向量化条件判断	推荐： 用于对数据框整列进行分类
for	固定次数循环	遍历已知长度的对象
break	强制跳出当前循环	满足特定错误或条件时停止
next	跳过本次循环，进入下一次	过滤不符合条件的样本
return()	指定函数返回值	提前结束函数或明确输出结果

Chapter 3

数据分析

3.1 数据清洗与转换 (dplyr & tidyr)

在 R 语言的的实际应用中，原始数据往往是“脏”的或格式不规范的。`tidyverse` 生态系统中的 `dplyr` 和 `tidyr` 提供了一套高度一致、语义化的工具。

3.1.1 dplyr 的核心动作 (Verbs)

`dplyr` 包通过几个核心动词函数，覆盖了大部分数据转换需求：

1. `filter()`：按行筛选数据。
2. `select()`：按列选取变量。
3. `mutate()`：衍生新列。
4. `arrange()`：数据排序。
5. `group_by()` 与 `summarise()`：分组聚合。

3.1.2 tidyr 的数据重塑

- `pivot_longer()`：将宽格式数据转换为长格式。
- `pivot_wider()`：将长格式数据转换为宽格式。

3.1.3 常用清洗函数对比总结

3.2 数据可视化 (ggplot2)

`ggplot2` 是 R 语言中最强大的可视化包。其核心逻辑是通过加号 (+) 将不同的图层叠加在一起。

函数	功能描述	SQL/Excel 对应
<code>filter()</code>	筛选满足条件的观察行	Filter / WHERE
<code>select()</code>	选取或剔除指定的变量列	Select / Column hide
<code>mutate()</code>	新增列并保留原数据	Calculated Field
<code>group_by()</code>	将数据按类别分组	GROUP BY
<code>summarise()</code>	将多行数据压缩为一行汇总结果	Pivot Table / Sum
<code>inner_join()</code>	根据键值合并两个数据框	VLOOKUP / JOIN

3.2.1 ggplot2 的基础语法结构

一个基本的绘图模板如下：

```
1 ggplot(data = <DATA>) +  
2   <GEOM_FUNCTION>(mapping = aes(<MAPPINGS>)) +  
3   <THEME_FUNCTION>()
```

1. **数据 (Data):** 必须是一个数据框 (`data.frame`)。
2. **映射 (Mapping):** 使用 `aes()` 函数定义，指定变量如何映射到视觉属性（如 `x` 轴、`y` 轴、颜色 `color`、形状 `shape`）。
3. **几何对象 (Geoms):** 决定图表类型（点、线、柱等）。

3.2.2 常见图表类型 (Geoms)

根据研究目的选择不同的几何对象函数：

- **散点图:** `geom_point()` ——用于观察两个连续变量的关系。
- **箱线图:** `geom_boxplot()` ——用于观察变量的分布及异常值。
- **条形图:** `geom_bar()` 或 `geom_col()` ——用于展示分类数据的频数或数值。
- **折线图:** `geom_line()` ——常用于时间序列数据。
- **直方图:** `geom_histogram()` ——观察单变量的分布密度。

3.2.3 图形美化：颜色、标签与主题

通过叠加额外的图层，可以让图表达达到出版标准。

```
1 df %>%
2   ggplot(aes(x = weight, y = height, color = group)) +
3   geom_point(size = 3, alpha = 0.7) +
4   labs(
5     title = "Weight vs Height",
6     x = "Weight (kg)",
7     y = "Height (cm)",
8     color = "Group Name"
9   ) +
10  theme_bw() # 使用经典白底黑框主题
```

3.2.4 分面 (Faceting)

分面是 ggplot2 最强大的功能之一，可以根据某个分类变量快速生成多张子图。

- `facet_wrap(~variable)`: 按一个变量自动排列子图。
- `facet_grid(rows ~ cols)`: 按行和列两个变量生成矩阵子图。

3.2.5 常用外观调整函数对照表

类别	函数	功能说明
坐标轴范围	<code>xlim()</code> , <code>ylim()</code>	设置 X 或 Y 轴的起止点
颜色比例	<code>scale_color_manual()</code>	手动指定离散变量的颜色(如实验组红色，对照组蓝色)
坐标翻转	<code>coord_flip()</code>	将 X 轴与 Y 轴对调(常用于条形图)
预设主题	<code>theme_minimal()</code>	极简主题，去除冗余网格线
保存图表	<code>ggsave()</code>	将最后生成的图表保存为 pdf, png 或 tiff 格式

注意事项: 1. 注意 `color` (轮廓色/点色) 与 `fill` (填充色) 的区别。柱状图的颜色通常使用 `fill`。2. 多个图层之间必须使用 `+` 连接，且 `+` 必须写在行末，不能写在行首。3. 如果在 `aes()` 内部设置颜色，它是根据数据自动映射；如果在 `aes()` 外部设置颜色(如 `geom_point(color = "blue")`)，则是统一指定颜色。

3.3 统计检验基础

R 语言提供了强大的内置函数，用于执行常见的参数化与非参数化检验。在执行检验前，通常需要确保数据满足正态性 (`shapiro.test()`) 和方差齐性 (`bartlett.test()`)。

3.3.1 均值比较 (T-Test & ANOVA)

1. **T 检验 (t-test)** 用于比较两组数据均值是否存在显著差异。

- 独立样本 T 检验：比较两组独立受试者。
- 配对样本 T 检验：比较同一受试者治疗前后的变化。

```
1 # 独立样本: y 是连续变量, group 是二分类因子
2 t.test(y ~ group, data = df)
3
4 # 配对样本
5 t.test(df$before, df$after, paired = TRUE)
```

2. **方差分析 (ANOVA)** 用于比较三组及以上数据的均值差异。

```
1 # 1. 拟合线性模型
2 fit <- aov(weight ~ group, data = df)
3
4 # 2. 查看 ANOVA 表
5 summary(fit)
6
7 # 3. 事后两两比较 (Tukey HSD)
8 TukeyHSD(fit)
```

3.3.2 相关性与回归分析

1. **相关性分析** 计算变量间的相关系数 (Pearson 或 Spearman)。

```
1 cor(df$age, df$blood_pressure, method = "pearson")
2 cor.test(df$age, df$blood_pressure) # 包含显著性检验
```

2. **线性回归 (Linear Regression)** 用于探究自变量 (x) 对因变量 (y) 的影响。

```
1 # 拟合模型: y = ax + b
2 model <- lm(y ~ x1 + x2, data = df)
3
4 # 查看结果 (包括系数、R方和 P 值)
5 summary(model)
6
7 # 提取残差
8 residuals(model)
```

3.3.3 常用统计函数速查表

注意事项: 关于 P 值 1. 在 R 的输出结果中, 星号通常代表显著性水平: *** ($P < 0.001$), ** ($P < 0.01$), * ($P < 0.05$), . ($P < 0.1$)。2. 对于回归模型, 在使用 `summary(model)` 后, 重点关注 `Coefficients` 表中的 `Pr(>|t|)` 列以及底部的 `Adjusted R-squared` (调整后 R 方)。

统计需求	R 函数	适用场景
正态性检验	<code>shapiro.test()</code>	判断数据是否符合正态分布 ($P > 0.05$)
二组均值	<code>t.test()</code>	两组连续变量比较
二组中位数	<code>wilcox.test()</code>	非正态分布数据的两组比较
多组均值	<code>aov()</code>	三组及以上均值比较 (ANOVA)
分类变量检验	<code>chisq.test()</code>	观察频数与期望频数的差异 (卡方检验)
线性模型	<code>lm()</code>	回归分析与预测